

硕士学位论文

(学术学位论文)

面向人类装配动作识别和预测方法研究

**RESEARCH ON HUMAN ASSEMBLY ACTION
RECOGNITION AND PREDICTION METHODS**

夏莹昕

哈尔滨工业大学

2025 年 5 月

国内图书分类号：TP274.3
国际图书分类号：681.5

学校代码：10213
密级：公开

工学硕士学位论文

面向人类装配动作识别和预测方法研究

硕 士 研 究 生：夏莹昕

导 师：张学贺 副研究员

申 请 学 位：工学硕士

学 科：机械工程

所 在 单 位：机电工程学院

答 辩 日 期：2025 年 5 月

授予学位单位：哈尔滨工业大学

Classified Index: TP274.3

U.D.C: 681.5

Dissertation for the Master Degree in Engineering

RESEARCH ON HUMAN ASSEMBLY ACTION
RECOGNITION AND PREDICTION METHODS

Candidate:	Xia Yingxin
Supervisor:	Assoc. Prof. Zhang Xuehe
Academic Degree Applied for:	Master of Engineering
Speciality:	Mechanical Engineering
Affiliation:	School of Mechatronics Engineering
Date of Defence:	May, 2025
Degree-Confering-Institution:	Harbin Institute of Technology

摘 要

随着制造业的发展，协作机器人在工业领域中的应用越来越普遍，为了提高协作机器人的智能性及与人交互的自然性，机器人需要对人体运动意图进行准确且及时的估计，并且根据结果进行相应的反应。本研究聚焦于面向人类装配动作识别与预测方法，旨在提高动作识别与预测技术的精度和效率，以实现流畅且自然的人机交互。

首先，针对人类动作感知的需求，搭建了基于深度相机的视觉感知系统，研究了相机标定方法与手部位姿估计技术，搭建了基于 MediaPipe Hands 框架的手部位姿估计方案，实现了手部关键点的实时检测，并提出了结合深度信息和相机内参对手部关节坐标进行优化的方法，以提高位姿估计的鲁棒性。

其次，针对单一模态表征能力有限的问题，设计并构建了一种多模态数据驱动的装配动作识别方法。该方法包括数据前处理、RGB 特征提取、关节运动特征提取、多模态特征融合等模块，通过融合 RGB 图像特征和手部关节特征，充分利用了多模态数据的互补性实现了精准的动作识别。基于公开数据集对模型的性能进行了评估，结果显示多模态的方案相较于单一模态的方案动作识别准确率提升了 4.24%，表明了多模态特征融合的有效性。

针对装配场景中的长时序动作预测难度较大的问题，研究了一种基于门控时序扩散网络的装配动作预测方法。该方法利用门控机制捕捉时序依赖关系，通过扩散过程预测未来的动作标签，实现了对装配动作序列的建模与预测。完成了整个动作预测网络的构建，并基于公开数据集对模型的性能进行了评估，对比了与其他模型之间的性能差异，实验结果表明，所提方法在长时序动作预测任务的精度方面优于其他方法。

最后，对所提的动作识别和预测方法展开实验验证，完成实验硬件平台的搭建和软件系统的开发，设计了数据采集与标注方案，完成了自建装配数据集的构建工作。对动作识别任务展开实验，结果表明，动作识别模型在自建数据集上的精度达到了 95.31%，验证了所提出方法的有效性。对动作预测任务展开实验，对不同观测比例下的预测结果进行了可视化分析，测试了模型在不同步长下的推理速度，结果表明，模型能够满足人机交互过程中的实时性需求。

关键词:动作识别；动作预测；动作感知；深度学习；扩散网络

Abstract

With the development of manufacturing, collaborative robots are increasingly being applied in industrial fields. To enhance the intelligence of collaborative robots and the naturalness of human-robot interaction, robots need to accurately and promptly estimate human motion intent and respond accordingly. This research focuses on human action recognition and prediction methods for human-robot collaboration, aiming to improve the accuracy and efficiency of action recognition and prediction technologies to achieve smooth and natural human-robot collaboration.

First, to meet the demand for human motion perception, a vision-based perception system using depth cameras was developed. The study investigated camera calibration methods and hand pose estimation techniques, implementing a hand pose estimation solution based on the MediaPipe Hands framework. This solution enables real-time detection of hand keypoints, and a method to optimize hand joint coordinates by combining depth information and camera intrinsic parameters was proposed to enhance the robustness of pose estimation.

Second, to address the limited representation capability of single-modal data, a multimodal data-driven assembly action recognition method was designed and developed. This method includes modules for data preprocessing, RGB feature extraction, joint motion feature extraction, and multimodal feature fusion. By integrating RGB image features and hand joint features, the complementary nature of multimodal data was fully utilized to achieve precise action recognition. The model's performance was evaluated on a public dataset, with results showing that the multimodal approach improved action recognition accuracy by 4.24% compared to single-modal methods, demonstrating the effectiveness of multimodal feature fusion.

To tackle the challenge of long-term action prediction in assembly scenarios, an assembly action prediction method based on a gated temporal diffusion network was studied. This method employs a gating mechanism to capture temporal dependencies and uses a diffusion process to predict future action labels, enabling modeling and prediction of assembly action sequences. The entire action prediction network was constructed, and its performance was evaluated on a public dataset, comparing its performance with other models. Experimental results showed that the proposed method outperforms others in accuracy for long-term action prediction tasks.

Finally, experimental validation was conducted for the proposed action

recognition and prediction methods. The hardware platform and software system were developed, and a data collection and annotation scheme was designed to build a custom assembly dataset. Experiments on action recognition demonstrated that the model achieved an accuracy of 95.31% on the custom dataset, verifying the effectiveness of the proposed method. For action prediction tasks, visual analysis was performed on prediction results under different observation ratios, and the model's inference speed at different step lengths was tested. Results show the model fulfills real-time demands for human-robot cooperation.

Keywords : Action Recognition, Action Prediction, Motion Perception, Deep Learning, Diffusion Network

目 录

第 1 章 绪论.....	1
1.1 课题来源.....	1
1.2 课题研究的背景和意义.....	1
1.3 国内外研究现状.....	3
1.3.1 动作识别研究现状.....	3
1.3.2 动作预测研究现状.....	8
1.4 国内外研究现状简析.....	10
1.5 本文的主要研究内容.....	12
第 2 章 基于视觉的动作感知与数据获取	14
2.1 引言.....	14
2.2 相机标定.....	14
2.2.1 视觉系统硬件与相机成像模型.....	14
2.2.2 相机标定实现.....	17
2.3 手部位姿估计.....	19
2.3.1 基于 MediaPipe Hands 的手部位姿估计方法.....	19
2.3.2 手部关节点坐标检测实现.....	20
2.3.3 融合深度信息的手部关节点坐标优化	22
2.4 本章小结.....	24
第 3 章 多模态数据驱动的装配动作识别方法研究	25
3.1 引言.....	25
3.2 动作识别公开数据集.....	25
3.3 结合 RGB 和手部关节点特征的动作识别网络	27
3.3.1 动作识别网络整体概述.....	27
3.3.2 数据前处理模块.....	27
3.3.3 基于 TSM-ResNet50 的 RGB 特征提取模块.....	28
3.3.4 基于 MS-TCN 的关节点运动特征提取模块	31
3.3.5 多模态特征融合模块.....	33
3.3.6 时序 Transformer 模块.....	34
3.3.7 学习目标.....	35
3.4 基于公开数据集的模型性能评估	36
3.4.1 实验环境与评价指标.....	36
3.4.2 基于 RGB 特征的动作识别网络实验评估	37
3.4.3 基于手部关节点的动作识别网络实验评估	40
3.4.4 多模态动作识别网络实验评估.....	43

3.5 本章小结.....	47
第4章 基于门控时序扩散网络的装配动作预测方法研究	48
4.1 引言.....	48
4.2 动作预测任务建模与数据预处理	48
4.2.1 动作预测任务建模.....	48
4.2.2 数据预处理.....	49
4.3 基于门控时序扩散的动作预测网络结构	50
4.3.1 扩散模型.....	50
4.3.2 门控时序预测网络.....	52
4.3.3 门控时序扩散网络.....	53
4.3.4 学习目标.....	55
4.4 基于公开数据集的装配动作预测实验与结果分析	56
4.4.1 评价指标.....	56
4.4.2 参数设计.....	57
4.4.3 实验结果与分析.....	58
4.5 本章小结.....	61
第5章 装配动作识别与预测实验	62
5.1 引言.....	62
5.2 实验环境搭建.....	62
5.2.1 硬件平台搭建.....	62
5.2.2 软件系统构建.....	63
5.3 装配实验设计与数据采集	65
5.3.1 多对象多序列装配任务设计.....	65
5.3.2 装配动作数据采集与标注.....	67
5.4 动作识别与预测实验与结果分析	70
5.4.1 动作识别实验与结果分析.....	70
5.4.2 动作预测实验与结果分析.....	74
5.5 本章小结.....	80
结论.....	81
参考文献.....	83

第 1 章 绪 论

1.1 课题来源

本课题来源于国家自然科学基金面上项目“基于多模态感知与自然语言理解的机器人自主任务规划方法研究”（62373129）。

1.2 课题研究的背景和意义

随着制造业的数字化转型，传统的大规模标准化生产模式正逐步向柔性化、智能化和个性化方向演进。在传统制造体系中，自动化装配系统受限于机电控制技术和人工智能发展水平，仅能针对固定产品类型执行重复性作业，难以满足现代市场对产品多样化和快速迭代的需求。近年来，得益于机器人技术和人工智能的突破性进展，工业协作机器人已实现从单一功能向智能协同的跨越式发展。以装配任务为例，机器人在协同中的作用多方面体现：一方面，机器人能够协助人类完成举起较重组件等繁重工作；另一方面，通过应用人工智能技术，机器人能够预测人类的下一步操作，提前准备所需的工具和组件或者提供辅助。这种人机协同作业模式在新一代制造系统中展现出显著的应用潜力，并成为驱动工业机器人向智能化演进的关键因素。



图 1-1 人机协作

在工业 5.0 的概念中突出了人与机器人之间的协同合作，强调了人的角色，将人类的创造力、智慧和灵活性与机器人的自动化能力相结合。如图 1-1 所示，这种人机协同模式在有效降低操作人员劳动强度的同时，通过优势互补确保了生产效率和产品品质。人机协作系统实现了人类灵活性与机器人精确性的互补：一方面，人类拥有更强的智能和自主决策能力，能够在突发情况下迅速做出适应性调整。然而，在需要长时间地执行作业时，人类因其精力的有限性难以一直保证工作质量。而协作机器人在力量和耐力等方面更为可靠，不会受到疲劳

影响而出现错误，具有高准确性特点，能够持续地完成重复的制造工作，同时其强大的力量可以代替人类完成一些重负荷操作。这种人机优势互补机制通过协同增效作用，可显著提升工业制造系统的整体效能。

随着人工智能、传感技术和鲁棒控制等领域的持续进步，这些赋予了机器人更高的智能水平，使之具备了更强的自主决策能力。这进一步加强了人机协作的协调性和灵活性，推动了制造企业在大批量生产的同时，也能够更好地满足个性化生产的需求。面向工业 5.0 框架的人机协同装配系统中，智能协作机器人通过集成视觉感知模块与自主决策功能，实现动态化人机交互。机器人利用视觉感知模块实时采集作业人员的肢体动作信息，依托人工智能算法判断人类的意图并做出相应反应，规划安全运动路径，实现与人类一起参与制造过程，共同完成复杂任务。通过这种智能化的机器人，制造企业可以更加灵活地适应市场需求的变化，实现高效率的生产和个性化定制的双重目标。

在传统的人机交互方式中，人类往往通过手势、语音、键盘等明确的指令来控制机器人，这些控制方式虽然简单却需要人类中断进行中的任务来发出指令，在一定程度上影响了协作的流畅性，降低了工作效率。为了实现交互性强且流畅灵活的人机协作，协作机器人需具备人类操作意图的自主辨识能力，并主动提供适配的协助，而不是被动地等待命令的下达。所以机器人必须具备一定的“智力”，能够识别人类的各种姿态和动作，同时推测其中隐含的人类意图，并做出相应的反应。人机协作中的人类行为识别与预测流程如图 1-2 所示。因此，如何实现机器人智能化的核心在于使其具备对人体动作的实时精准识别与解析能力，这构成了人机协同系统的关键技术瓶颈。该技术面临双重挑战：首先，识别精度不足将直接影响人机协同作业效率；其次，实时性缺陷同样会制约协作效能，尤其在复杂或高危作业场景下，动作识别系统的精度与实时性不足可能引发安全隐患。由此可见，在人机协同装配系统中实现高精度、低延迟的人体动作识别和预测具有重要的工程应用价值。




图 1-2 人机协作中的人类行为识别与预测流程

1.3 国内外研究现状

1.3.1 动作识别研究现状

人体动作识别作为跨学科研究领域，其技术基础涵盖计算机视觉、深度学习等人工智能核心技术，已成为当前智能视觉分析领域的重要研究方向。人体动作识别的目标是从输入的数据中提取出关键的信息，比如人体姿势、动作类型和运动时序，这些数据可以是来自普通摄像机、深度传感器、惯性传感器等的图像、视频或时间序列数据，通过分析这些数据，人体动作识别技术可以自动识别并分析人体的运动和动作，以便于计算机系统能够理解人类的动作并做出相应的响应。这一技术的应用范围涵盖了多个领域，从虚拟现实、人机交互，到医疗康复和安全监控等。

人体动作识别对视频序列进行人体动作特征提取、特征表示和动作识别等操作的过程，其中特征的提取和表示是十分关键的步骤，将会直接影响到最终的动作分类结果。基于获取特征方法的差异性，动作识别可以分为传统方法和深度学习法^[1]，传统方法依赖人工特征提取，难以适应大数据处理需求，而深度学习法使用神经网络实现特征的提取，弥补了手工提取的一些缺陷。如图 1-3 所示，展示了用这两种方法实现人体动作识别的流程对比。




图 1-3 传统方法与深度学习方法流程对比^[2]

（1）基于手工特征的传统动作识别方法

传统的动作识别技术依赖更多的先验知识，从运动信息和空间信息中通过人工观察、手工表征获取人体运动特征，将得到特征作为视频的表达式，然后利用统计学习中的分类方法实现动作分类。其中特征可以细分为整体特征表示和局部特征表示。整体特征方法通过分析视频帧的全局信息（如轮廓剪影、关节点等）进行动作表征^[2]。其中比较有代表性的包括 Bobick 等^[3]设计出的 MEI(motion energy image)、MHI(motion history image)，前者用于描述运动的空间分布，后者用于描述人体的运动方式；Yilmaz 等^[4]使用 STV(space-time

volume)表示叠加给定序列的视频帧,获取动作描述,实现动作识别;Fujiyoshi等^[5]提出了五关节星形图,实现了视频流中人体四肢及头部关键点的实时检测;Yang等^[6]利用深度相机捕获的深度数据成功检测3D人体关节点以实现动作识别。

局部特征法在视角变化和遮挡等复杂场景下表现出更强的鲁棒性,其典型例子包括时空兴趣点检测和运动轨迹分析。时空兴趣点的概念由Laptev^[7]提出,是将人类行为信息使用兴趣点描述的一种方法。运动轨迹特征是利用人体骨骼关节点的轨迹来表示行为,其中最具代表性的是Wang等^[8]提出的密集轨迹方法(IDT),其原理如图1-4所示。传统方法的人类动作识别技术受到了物体遮挡、环境中的噪声与光照等因素的影响,应用场景受到一定的限制。尽管这些方法在当前研究中关注度较低,但其蕴含的先验知识仍对现代技术发展具有重要参考价值。




图 1-4 IDT 密集轨迹方法原理图^[8]

深度学习凭借其卓越的特征学习能力、环境适应性和跨平台迁移特性,已成为视觉领域的主流研究方法,研究者们尝试将深度学习应用于人体动作识别技术上。深度学习通过高效的算法可以实现自动对数据进行特征学习和特征提取。在人体动作识别领域,国内外学者努力开发算法和模型,使计算机能够准确且高效地捕获和理解人体在不同时间和空间上的动作变化。基于深度学习的动作识别技术依据输入数据形式可分为两类典型方法,基于RGB的端到端动作识别方法和基于骨架的级联动作识别方法。

(2) 基于RGB的端到端动作识别

基于RGB的端到端动作识别方法直接对RGB视频流进行特征学习与分类,实现了从原始数据到动作类别的直接映射。根据使用的网络结构的不同可分为双流法、3D卷积法及其他基于LSTM或GCN的方法。

双流卷积网络是2014年Simonyan等^[9]在神经信息处理系统大会NIPS上提出一种用于动作识别和行为分析的深度学习架构,也是基于深度学习的视频理解领域的开山之作,识别效果首次超过了传统手工设计的特征。双流网络的

基本流程如图 1-5 所示。该架构将行为识别分为空间流和时间流，前者用于提取运动物体外观特征，后者用于提取运动特征。之后的研究者对双流网络又进行了一系列改进以提升其性能。Wang 和 Xiong 等^[10]提出了时域分割网络(TSN)，提升了双流网络对长期运动的识别效果，同时大幅降低了数据量。Feichtenhofer 等^[11]提出了时空残差网络模型(STResNet)，实现了对双流网络和残差网络的结合，提高了双流网络识别的准确性。Qiu 等^[12]提出了一种基于局部和全局扩散(LGD)的时空表示学习框架，有效结合了局部和全局特征，增强了对视频特征的表达能力。Wang 等^[13]在卷积神经中加入注意力机制，强化了双流网络对局部特征变化的识别。双流卷积网络能够全面地捕获动作和行为特征，适应动态场景，但计算和内存成本高，数据需求量大。




图 1-5 双流网络框架^[9]

在双流法中空间和时间信息是分离的，3D 卷积法则是直接同时提取时间维度和空间维度的特征。3D 卷积相对于图像识别领域的 2D 卷积增加了一个维度以用于捕捉数据中的时间维度，使之能够更好地处理具有时间关联性的数据，可以用于视频行为分析。Ji 等^[14]首先提出将 3D 卷积应用到视频理解中的想法，实现了从视频中的时空特征提取。Tran 等^[15]在此基础上，提出了 C3D(Convolutional 3D)，使用大规模数据集进行训练，提升了相关算法的泛化能力。Diba 等^[16]将时间过渡层(TTL)引入 3D 卷积中，同时将 DenseNet 网络结构扩展 3D 形成 DenseNet3D，构建形成了新的网络 Temporal 3D ConvNets(T3D)，有效提高了行为识别的准确率。Qiu 等^[17]针对三维卷积网络参数量大的问题，改进残差网络，提出了一种结合二维空间卷积与一维时间卷积以近似三维卷积的方法，以此提出了 Pseudo-3D Residual Net (P3D ResNet)，提升了网络性能。Kim 等人^[18]开发的 TA3DNet 网络通过弱监督学习机制优化时序注意力模块，实现了轻量化 3D 卷积架构，显著降低视频处理所需的帧数。3D 卷积神经网络具有能直接提取时空特征、特征提取能力强等优点，但也有许多缺点，如巨大的计算成本、大量的参数，收到卷积核大小的限制不能很好地提取长时信息。

双流法和 3D 卷积法各有其弊端，研究者们又提出了一些其他的动作识别方法，如基于 LSTM 的动作识别方法和基于 GCN 的动作识别方法。LSTM 非

常适合处理与时间序列高度相关的问题，因此在处理视频信息方面具有优势。He 等人^[19]提出了一种融合卷积神经网络空间特征提取与长短时记忆网络时序建模优势的深度双向 LSTM 架构，该模型在长时视频序列分析任务中表现出优越性能。Girdha 等人^[20]采用 Transformer 架构进行上下文特征融合，并通过注意力机制来强调手和面部特征。GCN 相较于 CNN 在处理非欧几里得结构数据时具有很大的优势。Zhou 等人^[21]提出了一种基于图的高阶关系建模方法 (GHRM)，该模型能从长期动作中提取高阶特征之间的相关性。

(3) 基于骨架的动作识别

基于骨架的级联动作识别方法是先从原始视频数据集中通过姿态估计检测出人体骨骼关节点以获取骨骼数据集，然后在此基础上实现动作识别的一种方法。为了获取骨骼数据集需要实现姿态估计，主要方法包括自顶向下法和自底向上法，目前很多深度相机都具备相关的功能包，能够直接获取人体骨骼关节点数据。骨架数据通过关节坐标表征人体动作，具有数据量小的优势。相较于 RGB 视频易受光照变化和噪声干扰的特性，基于骨架的动作识别方法展现出更强的环境适应性。

LSTM 在时间序列特征提取方面具有很大的优势。为有效捕获动作序列的多尺度时序特征，研究者普遍采用短期、中期和长期特征划分策略^[22]。Lee 等^[23]创新性地提出集成时序滑动 LSTM (TS-LSTM) 网络，该架构通过多时间步长的 LSTM 单元分别建模骨架动作的不同时序特性。针对传统 LSTM 在关节点特征关注度方面的局限性，Song 等^[24]设计了一种端到端时空注意力网络，该网络通过时间维和空间维的双重注意力机制增强了对关键运动特征的捕捉能力。Liu 等^[25]提出的 GCA-LSTM 网络创新性地整合了全局上下文感知机制，通过专用记忆单元实现对视频帧中关键关节的动态选择性关注。为了使 LSTM 更高效地提取空间信息，Zhu 等人^[26]采用正则化方法挖掘骨架数据的共现特征，该特征能有效表征组合时空信息，提升网络特征表征能力。Si 等人^[27]提出了一种能挖掘时空特征的注意力增强的图卷积 LSTM 网络 (AGC-LSTM)，同时提出了一种时间分层结构，可以增加时域接收域。

基于 CNN 的方法通常采用骨架数据图像化处理策略，其核心是将原始骨架信息编码为彩色纹理图像，进而利用 CNN 提取视觉特征，骨架数据本质上被视为一种特殊的图像特征进行处理^[28]。Du 等^[29]开发了分层式端到端框架，该框架首先将骨架坐标序列化表示，经时序连接转换后生成图像特征，最终通过 CNN 完成识别任务。类似地，Ding 等人^[30]提出了骨骼数据到彩色纹理图像的转换方法，直接利用 CNN 提取高层语义特征，具体过程如图 1-6 所示。Liu 等人^[31]采用分层的方法，使用 CNN 来捕捉骨架关节之间的微观时间关系，然

后使用傅里叶时间金字塔来挖掘它们的宏观时间关系。Duan 等人^[32]创新性地构建了 PoseConv3D 网络用于骨架行为识别，并证实当姿态估计结果包含关键动作模式时，即使存在质量缺陷仍可有效完成识别任务。




图 1-6 基于 CNN 的骨架序列的 3D 行为识别网络结构^[30]

基于 GCN 的方法相较于传统 CNN 和 RNN 模型具有独特优势，其能够直接处理非欧几里得拓扑结构数据，并通过图结构实现深层次特征学习，而骨骼关节点结构属于非欧式空间结构，故使用 GCN 处理骨骼关节点可以得到更好的效果。Yan 等^[33]创新性地设计了时空图卷积网络(ST-GCN)，该架构通过双分支特征提取机制实现骨架动作的时空特征自动学习，在时间维度采用一维卷积捕捉关节跨帧运动模式，在空间维度利用图卷积解析骨骼拓扑关系，网络架构见图 1-7，该方法将 GCN 正式应用于骨架行为识别的研究工作，为后续研究奠定了重要基础。Li 等^[34]提出的动作结构图卷积网络(AS-GCN)针对 ST-GCN 仅建模直接连接关节的局限性，创新性地引入非相邻关节关联机制，有效提升了模型对远距离关节点间交互特征的捕捉能力。考虑到上下文信息在视频序列数据识别中的重要性，Zhang 等^[35]结合全局上下文信息，便于提供局部运动特征。Chen 等人^[36]提出了一种新的通道级拓扑精化图卷积(CTR-GC)，由于放松了图卷积的严格约束，具有更强的表示能力。




图 1-7 基于 ST-GCN 的行为识别架构^[33]

目前已经有大量的工作致力于人类动作识别，这被认为在人机协作中也能发挥关键作用，增强机器人的智能化。因为人类的行为可能表现出一定的模糊性，这使得机器人很难采取相应或主动的行动。针对这一问题，研究者们开始投入精力到面向人机协作场景的人类动作识别当中。但动作的复杂性和有限的数据集还是在一定程度上制约了人机协作场景中动作识别方法的通用性。针对

工业人机协作装配任务中子装配任务的识别, Wen 和 Chen 等^[37]研究设计了一种 CNN 和 LSTM 结合的网络用于实现子装配任务中的人体动作识别,可以满足更高的精度要求和更长的时间跨度。Li 等^[38]提出了一种基于迁移学习的动作识别方法,以促进人机协作装配中的机器人反应控制。该研究的目标是通过深度迁移学习网络从一般的日常动作表示学习到制造活动的知识。Male 等^[39]提出了一种面向协同装配任务的由感知和推理模块组成的机器人认知架构,允许机器人在装配任务中与人类合作的同时调整其动作。该研究使用带有惯性测量单元和 Kinect 相机捕获的人体骨架信息作为数据源,将其输入卷积神经网络模型进行人体动作识别感知,还设有任务状态推理模块可以预测任务中每个动作的剩余时间。

为提升人机协作装配中的意图理解能力,李芳^[40]开发了一种基于骨骼特征的动作识别方法。该方法利用 Kinect 传感器采集七步椅子组装过程的骨骼数据,通过引入注意力机制的改进型双流神经网络实现动作分类。在人机协同制造领域,李琦^[41]设计了一种创新的三维卷积识别框架,该框架整合了 ABYOLOv4 目标检测、VTTransPose 姿态估计和 TPoseC3D 动作识别三个模块,经公开数据集和实际场景验证具有优异的识别精度与鲁棒性。针对实时意图识别需求,张贺龙^[42]的研究融合了骨架特征分析与改进 YOLO v3 检测算法,构建了高效的识别系统。李佳英^[43]提出了一种结合 ST-GCN 时空特征提取与 Transformer 序列决策的方法,并基于数字孪生技术开发了集成系统,实验证明该方法能显著提高装配效率和改善用户体验。这些研究在一定程度上推动了人机协作场景中动作识别技术的发展。

1.3.2 动作预测研究现状

行为预测是计算机视觉和人工智能交叉领域的重要研究方向之一,其核心目标是根据视频中的当前和过去时刻的观察,预测未来的行为,从而为运动损伤预防、智能监控、人机交互等应用提供支持。随着多个基准数据集的引入,这一任务逐渐受到越来越多的关注。这些数据集包括近期的 EPIC-KITCHENS^[44]、Ego4D^[45]、Assembly101^[46],和较早期的 Breakfast^[47]、EGTEA^[48],它们为研究者提供了丰富的实验平台。

现有文献根据预测范围的长短,将行为预测方法分为短期和长期两种。短期预测方法主要关注未来很短时间内即将发生的单一行为。例如, Girdhar 和 Grauman^[49]提出了一种名为 AVT 的模型,旨在通过注意力机制预测视频中的未来动作;Zhao^[50]等人提出了一种名为 TeSTra 的新型实时在线视频检测模型,整体框架如图 1-8 所示,它通过高效的注意力机制和时间平滑技术,实现了在

长视频流中快速且准确地检测和预测动作；Zhong^[51]等人提出了一种名为 AFPT 的新型多模态融合方法，利用多模态数据的互补性来预测下一个动作。这些方法通常利用视频中的局部信息，通过学习行为的短期模式来实现预测。相比之下，长期行为预测方法则具有更长的预测范围，能够预测多个未来行为，甚至可以预测几分钟后的行为。这类方法在实际应用中具有重要意义，例如自动驾驶和人机交互等领域，因为它们需要提前规划和决策。




图 1-8 TeSTra 整体框架^[50]

Farha 等人^[52]提出了确定性长期密集动作预测任务的定义，即预测视频中未来一段时间内（长达 5 分钟）将要发生的所有行为，包括行为的类别、顺序以及每个行为的开始和结束时间。他们还引入了基于 CNN 和 RNN 网络的不同预测模式来解决这一问题，并得出 RNN 在短期预测中表现更好，而 CNN 在长期预测中表现更好的实验结论。Farha 等人^[53]之后又提出了一种端到端的序列到序列模型，直接将观察到的视频帧映射到未来行为及其持续时间的序列，同时引入了一个基于时间卷积网络的识别模块用于预测未来行为的判别性特征，还引入了一个循环一致性模块，该模块能够根据预测的未来行为反向预测过去的活动，为处理长视频序列和复杂行为模式提供了新的方法。Gong 等^[54]提出一种端到端注意力模型，通过并行解码和全局注意力机制，有效地捕捉了过去和未来行为之间的长期依赖关系，从而在长期行为预测任务中取得了显著的性能提升。Ke 等人^[55]提出了一种新颖的时间条件化方法，通过显式地将时间参数纳入预测网络，使得模型能够高效地预测长期动作。Nawhal 等人^[56]提出一种两阶段的学习方法，通过结合片段级和视频级表示，能够更全面地捕捉视频中的信息，从而更准确地进行长期行为预测。Sener 等人^[57]提出了一种用于长期视频理解的时间聚合表示框架，通过灵活地聚合不同时间范围内的信息，该方法能够有效地处理从短期到长期的预测任务。

随着动作预测技术的发展，一些研究者尝试将其运用到人机协作中，以促

进人机之间的高效互动和安全协作。Zhang 等^[58]提出了一种混合机器学习方法用于人机协作中的动作识别和预测,该方法结合了卷积神经网络(CNN)和变长马尔可夫模型(VMM),通过双流 CNN 结构解析视频中的人类和物体信息,然后利用 VMM 分析动作序列的依赖关系,以实现对未来动作的准确预测,为提高人机协作的安全性和效率提供了新的技术手段。Zhang 等^[59]采用了一种基于状态增强的卷积长短期记忆(ConvLSTM)模型,通过“从演示中学习”技术使机器人能够理解任务描述和人类工人的个性化工作偏好,并预测人类工人的未来动作以提供主动支持。Zhang 等^[60]开发了一种面向人机协同装配场景的人-物融合式装配意图识别技术,利用基于骨架特征的时空图卷积网络(ST-GCN)模型快速准确地识别装配动作,并提出一种改进的 YOLOX 模型来识别装配部件,通过将这两种识别信息整合到基于规则的推理方法中,机器人能够在复杂多变的人机协作装配环境中准确判断操作者的当前装配意图。Li 等^[61]提出了一种用于人机协作装配的多模态迁移学习使能的动作预测方法,通过视觉流和骨架流的短期输入帧来预测正在进行的人类动作,并采用了迁移学习模型,将日常活动中的知识快速迁移到工业装配操作中,可在线分析操作者意图。

Zhang 等^[62]研究了人机协作中人类意图的早期预测,利用隐马尔可夫模型(HMM)确定从不确定意图到确定意图的状态转换时间,接着使用两种模型 Transformer 和 Bi-LSTM 用于分类运动意图。Precup 等^[63]探讨了在智能工厂背景下,通过分析人类工人的特征(如身高、性别、睡眠质量、是否戴眼镜等)以及当前装配状态,利用 DBN 来预测下一个装配步骤,以开发一个辅助人类工人进行制造活动的装配支持系统。在协作装配意图识别领域,杜慧龙^[64]创新性地采用了数据与知识协同驱动的研究范式,该研究首先构建了装配知识图谱作为基础框架,继而通过多源证据融合与知识推理技术实现了意图识别与预测功能,在一级教学减速器装配场景中验证了该方法兼具有效性与可解释性。另一方面,刘倡荣^[65]的研究聚焦于多模态意图预测,其技术路线整合了基于 TSM-ResNet50 和 Refined-MS-TCN 的两阶段动作识别分割网络,并引入任务约束的隐马尔可夫模型来完成意图预测任务。这些研究展示了动作预测技术在人机协作领域的多样化应用和发展趋势。通过结合深度学习、迁移学习、强化学习和传统机器学习方法,研究者们不断探索如何更准确地预测人类工人的意图和动作,从而提升人机协作的效率和安全性。

1.4 国内外研究现状简析

(1) 单模态的动作识别方法存在局限性

动作识别是计算机视觉领域的关键研究方向之一,近年来在研究者的努力

下取得了显著进展。根据特征提取的方式不同,动作识别方法可分为传统手工特征提取和基于深度学习的方法实现特征提取。深度学习方法因其强大的学习能力和适应性,以及较高的可移植性,已成为当前行为识别领域的主流方法。动作识别方法依据输入数据类型可分为两类:基于 RGB 视觉信息的识别方法和基于人体骨架数据的识别方法。然而,基于 RGB 图像的方法通常容易受到复杂背景、光照变化和其他外部因素的影响。光流仅表示相邻帧之间的像素级差异,传统基于光流的人体动作识别方法计算速度慢。相比之下,基于骨架的行为识别方法对上述因素具有较强的鲁棒性,并且由于只需要处理骨架数据而具有较少的计算消耗,但这也会使得基于骨架信息的行为识别忽略了一些对动作识别有用的上下文信息。

(2) 长期动作预测任务存在累积误差和计算效率的问题

动作预测领域的研究涵盖了从短期到长期的多种预测任务。短期预测方法主要依赖于视频中的局部信息,通过学习行为的短期模式来实现快速且准确的预测,适用于需要即时反应的应用场景,如运动损伤预防和实时监控。长期预测方法则更加注重对视频全局信息的建模,能够预测多个未来行为及其时间安排,这对于需要提前规划和决策的应用,如自动驾驶和人机交互,具有至关重要的意义。然而,长期预测方法在处理长视频序列和复杂行为模式时面临着累积误差和计算效率的问题。

(3) 人机协作中动作识别与预测实时性、多模态融合与长时序预测挑战

一些研究者将动作识别与预测应用于人机协作领域,期望通过识别和预测人类操作员的动作,使机器人能够做出响应,从而实现对人的协助。他们尝试使用视觉传感器,或结合触觉传感器、惯性传感器等其他传感器,基于长短期记忆网络(LSTM)、卷积神经网络(CNN)或强化学习等方法,构建相应的工业数据集进行训练和测试,以实现人机协作中的人类动作识别。尽管已经取得了一些研究成果,但仍存在改进空间。例如,一些研究通过多种传感器进行信息融合,虽然在一定程度上提高了识别精度,但佩戴外部传感器给工人带来了不便。另一些研究在离线数据集上取得了良好效果,但由于计算量大,难以应用于实时监测系统,而机器人响应的及时性是人机协作的关键。因此,要将行为识别真正应用于人机协作,必须能够实现在线监测,这对行为识别模型的运行效率提出了较高要求。针对人机协作中的动作识别任务,如何结合人类操作员的人体运动信息与装配场景中作业对象的上下文信息,对模型的运行效率和精度有着重要影响。针对人机协作中的动作预测任务,目前的技术主要侧重于短期动作预测,难以满足复杂非结构化、非固定任务的协作装配环境的需求。

为了实现流畅的人机协作,本研究聚焦于提升动作识别与预测技术的效率

与精度。本研究采用纯视觉方案进行动作识别与预测，避免了佩戴外部传感器给操作员带来的不便，同时增强了系统的灵活性与适应性。针对效率和精度的问题，本研究通过融合手部关节运动信息与 RGB 视觉信息实现精准的动作识别。手部关节运动信息能够精确捕捉操作员的细微动作，而 RGB 信息则提供了丰富的视觉上下文，有助于理解装配场景中的整体情况，这种融合方法在保证运行效率的同时，显著提升了动作识别的准确性。针对目前人机协作场景长期动作预测还存在不足的问题，本研究将研究重点放在动作的长期预测上，旨在预测未来一段时间内的多个动作及其顺序。通过长期预测，机器人可以提前规划其动作，从而更好地适应动态变化的协作环境。

1.5 本文的主要研究内容

随着制造业的发展，协作机器人在工业领域中的应用越来越普遍，为了提高协作机器人的智能性及与人交互的自然性，机器人需要对人体运动意图进行准确且及时的估计，并且根据结果进行相应的反应。本文聚焦于人类装配动作识别与预测方法，重点解决装配顺序和装配对象不固定的人机协作装配场景中的动作识别与长期预测问题，以提升动作识别与预测技术的精度与效率。本研究的具体研究内容如图 1-9 所示。




图 1-9 主要研究内容流程图

（1）基于视觉的动作感知与数据获取

基于深度相机建立视觉感知系统，研究相机标定方法与手部位姿估计技术。搭建基于 MediaPipe Hands 框架的手部位姿估计方案，实现手部关键点的实时检测，提出结合深度信息和相机内参对手部关节点坐标进行优化，提高位姿估计鲁棒性，为后续研究提供可靠的动作数据来源。

（2）多模态数据驱动的装配动作识别方法研究

针对单一模态表征能力有限的问题，研究一种多模态数据驱动的装配动作识别方法。对数据前处理、RGB 特征提取、关节点运动特征提取、多模态特征融合等模块进行设计与构建，通过融合 RGB 图像特征和手部关节点特征，充分利用多模态数据的互补性，构建一个高效准确的动作识别网络。基于公开数据集对模型的性能进行评估，对比多模态与单一模态动作识别网络的性能差异。

（3）基于门控时序扩散网络的动作预测方法研究

针对装配场景中的长时序动作预测难度较大的问题，研究一种基于门控时序扩散网络的装配动作预测方法。将扩散模型的生成能力与门控时序网络的动态特征提取能力相结合，利用门控机制捕捉时序依赖关系，通过扩散过程预测未来的动作标签，实现对装配动作序列的建模与预测。完成整个动作预测网络的构建并基于公开数据集对模型的性能进行评估，对比与其他模型之间的性能差异。

（4）系统集成与实验验证

对所提的动作识别和预测方法展开实验验证，完成实验硬件平台的搭建和软件系统的开发。针对装配任务特点，设计数据采集与标注方案，完成自建装配数据集的构建与标注工作，保证数据多样性。对动作识别与动作预测任务展开实验，记录实验中的各项性能指标，并进行可视化分析，评估方法在识别准确率、预测精度和实时性等方面的性能表现。

第 2 章 基于视觉的动作感知与数据获取

2.1 引言

在面向人机协作装配场景的动作识别研究中,准确获取操作者的动作信息是实现自然交互的基础前提。基于视觉的动作感知技术因其非接触式、高灵活性的特点,成为当前人机协作领域的重要研究方向。本章围绕视觉动作感知系统的构建展开研究,重点解决三个关键问题:首先,针对视觉传感器固有的畸变问题,对相机进行标定获得其内参;其次,为实现对操作者手部动作的精确捕捉,研究基于深度学习的手部位姿估计方法;最后,通过融合深度信息以及相机内参优化关节点坐标,提升三维空间中的手部关节点估计准确性。本章建立的视觉动作感知系统将为后续动作识别与预测研究提供可靠的数据支持。

2.2 相机标定

2.2.1 视觉系统硬件与相机成像模型

本研究所使用的用于捕捉人体运动信息的视觉传感设备为 Azure Kinect DK。Azure Kinect DK 是一款由微软公司开发的多功能传感器设备,广泛应用于计算机视觉、机器人技术、人体动作捕捉和三维重建等领域。它集成了 RGB 传感器、深度传感器、红外传感器、麦克风阵列以及加速度计和陀螺仪等多种传感器,能够同时提供彩色图像、深度图像、红外图像和音频数据,为多模态数据采集提供了强大的硬件支持。如图 2-1 所示是 Azure Kinect DK 外观示意图,其外观设计紧凑,便于集成和部署。其中 RGB 摄像头用于捕捉彩色图像;深度传感器和红外摄像头则用于生成深度信息;麦克风阵列和运动传感器分别用于音频采集和设备姿态检测。




图 2-1 Azure Kinect DK 外观示意图

Azure Kinect DK 的各项参数决定了其在不同应用场景中的性能表现。表

2-1 是其主要参数的详细说明。Azure Kinect DK 的 RGB 摄像头和深度摄像头是其核心部件，能够提供高质量的彩色图像和高精度的深度数据。其深度摄像头采用先进的 ToF(Time-of-Flight)技术，能够在较宽的测量范围内实现快速、准确的深度测量。此外，设备还配备了红外摄像头和麦克风阵列，进一步扩展了其在多模态数据采集中的应用能力。

表 2-1 Azure Kinect DK 性能参数

性能参数	参数数值
RGB 摄像头最大分辨率	3840×2160
深度摄像头最大分辨率	640×575
可见视野范围	0.5-5.46m
最大帧率	30FPS

基于光学投影原理，三维空间点可通过几何变换映射至二维像平面，这一过程构成了相机成像的数学基础。其中，针孔相机模型作为最基础的成像模型，采用理想化的小孔成像假设：空间任意物点与光心（针孔位置）的连线与像平面相交，形成对应的倒立像点。该模型通过简化的几何关系描述了从三维场景到二维图像的投影过程。

首先定义不同坐标系中的点坐标，如图 2-2 所示。世界坐标系是以场景中的某一点为原点，定义三维空间中的点 $P_w = (X_w, Y_w, Z_w)$ ；相机坐标系是以相机的光心为原点，Z 轴与光轴重合，定义点 $P_c = (X_c, Y_c, Z_c)$ ；图像坐标系是以成像平面的中心为原点，定义点 $p = (x, y)$ ，单位为米；像素坐标系是以图像的左上角为原点，定义点 $p' = (u, v)$ ，单位为像素。




图 2-2 不同坐标系中的点

世界坐标系中的点 P_w 可以通过相机的外参（旋转矩阵 R 和平移向量 t ）转换

到相机坐标系 P_c 中，公式如下：

$$\begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (2-1)$$

其中， R 为 3×3 的旋转矩阵， t 为 3×1 的平移向量。

相机坐标系中的点 $P_c = (X_c, Y_c, Z_c)$ 通过针孔模型投影到图像平面 $p = (x, y)$ ，投影过程中的坐标变化关系如下：

$$x = f \cdot \frac{X_c}{Z_c}, y = f \cdot \frac{Y_c}{Z_c} \quad (2-2)$$

其中， f 为相机的焦距。

图像坐标系中的点 $p = (x, y)$ 还需要转换为像素坐标系中的点 $p' = (u, v)$ ，这一转换包括缩放和平移两个步骤。

缩放是根据像素的物理尺寸（即每个像素在 x 和 y 方向上的大小）进行缩放。设 dx 和 dy 分别为每个像素在 x 和 y 方向上的物理尺寸（单位为米/像素），则缩放后的坐标为：

$$u' = \frac{x}{dx}, v' = \frac{y}{dy} \quad (2-3)$$

图像坐标系的原点位于成像平面的中心，而像素坐标系的原点位于图像的左上角。因此，需要对缩放后的坐标进行平移。设 (c_x, c_y) 为主点坐标（即图像中心点在像素坐标系中的位置），则平移后的坐标为：

$$u = u' + c_x, v = v' + c_y \quad (2-4)$$

将上述缩放和平移过程用矩阵形式表示，得到内参矩阵 K ：

$$K = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \quad (2-5)$$

其中， $f_x = \frac{f}{dx}$ 和 $f_y = \frac{f}{dy}$ 分别为相机在 x 和 y 方向上的焦距（以像素为单位）， (c_x, c_y) 为成像平面图像中心点的像素坐标。

投影过程可以将相机坐标系中的点坐标转化为像素坐标系中的点坐标，可以表示为：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K \cdot \begin{bmatrix} X_c \\ Y_c \\ Z_c \end{bmatrix} \quad (2-6)$$

联合上面所有的表达式，最终可以得到像素坐标系上的点和世界坐标系上的点的关系如下：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x & 0 \\ 0 & f_y & c_y & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \cdot \frac{1}{Z_c} \cdot \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (2-7)$$

实际相机由于透镜的存在，会引入径向畸变和切向畸变，导致图像失真。为了校正畸变，需要对图像坐标进行修正。

径向畸变是由于透镜形状导致的图像边缘扭曲，通常表现为“桶形畸变”和“枕形畸变”，其数学模型如下：

$$x_{corrected} = x(1 + k_1r^2 + k_2r^4 + k_3r^6) \quad (2-8)$$

$$y_{corrected} = y(1 + k_1r^2 + k_2r^4 + k_3r^6) \quad (2-9)$$

其中， k_1, k_2, k_3 径向畸变系数， $p = (x, y)$ 为归一化图像坐标， $r^2 = x^2 + y^2$ 。

切向畸变是由于透镜与成像平面不平行引起的畸变，其数学模型如下：

$$x_{corrected} = x + [2p_1xy + p_2(r^2 + 2x^2)] \quad (2-10)$$

$$y_{corrected} = y + [2p_2xy + p_1(r^2 + 2y^2)] \quad (2-11)$$

其中， p_1, p_2 为切向畸变系数。

综上，RGB 相机的成像过程可以总结为以下步骤：

- 1) 将世界坐标系中的点 P_w 通过外参 R 和 t 转换到相机坐标系 P_c ；
- 2) 将相机坐标系中的点 P_c 通过针孔模型投影到图像平面 p ；
- 3) 将图像坐标系中的点 p 转换为像素坐标系中的点 p' ；
- 4) 对图像坐标进行畸变矫正，得到最终的像素坐标。

2.2.2 相机标定实现

通过上一小节内容可以了解到在相机成像过程中的一些相关参数，相机标定是计算机视觉和图像处理中的重要环节，其核心目的是通过精确测量相机的内部参数（如焦距、主点、畸变系数等）和外部参数（如旋转矩阵和平移向量），将二维图像坐标与三维世界坐标建立准确的映射关系。通过相机标定结果，可以获取畸变参数并进行校正，从而提高图像的几何精度。此外，本研究需要用的方法涉及到了手部位姿估计，手部的三维姿态需要通过二维图像进行重建，而这一过程依赖于相机的精确参数。标定后的相机参数能够确保手部关键点在图像中的位置与实际三维空间中的位置之间存在准确的对应关系，并消除畸变对手部关键点检测的影响，从而提高位姿估计的精度。

本研究所使用的相机标定方法为张正友标定法。在众多相机标定方法中，张正友标定法因其简单、高效且易于实现而被广泛应用。张正友标定法的核心思想是利用已知几何特征的平面标定板（如棋盘格），通过拍摄多张不同角度

的标定板图像，估计相机的内参和外参。

首先选择标定板，本研究使用了棋盘格标定板，如图 2-3 所示，其角点在标定板的坐标系中具有已知的三维坐标，棋盘格的尺寸为 11×8 ，每个格子的大小为 24mm，采集 20 张不同姿态下的标定板图像，同时确保标定板在图像中的位置和姿态多样化。




图 2-3 棋盘格标定板

接着通过图像处理算法提取标定板上的角点，并对检测到的角点进行亚像素级优化，提高角点定位精度，将其与标定板的已知坐标进行匹配。角点检测结果如图 2-4 所示。




图 2-4 标定板角点检测结果

最后利用角点的图像坐标和标定板的已知坐标，构建齐次方程组，使用优化算法估计相机的内参矩阵和畸变系数，同时计算重投影误差用于衡量标定结果的精度。重投影误差是指将三维世界坐标重新投影到图像平面后，与检测到的角点坐标之间的差异。最终获得的相机参数如表 2-2 所示。其中重投影误差小于 0.5 像素，可以认为标定结果是比较理想的。

表 2-2 标定结果

相机参数	参数数值
内参矩阵	$\begin{bmatrix} 666.074247 & 0 & 634.027568 \\ 0 & 721.412164 & 355.925274 \\ 0 & 0 & 1 \end{bmatrix}$
畸变系数	$[0.133848 \quad -0.131578 \quad -0.016027 \quad 0.000724 \quad 0.089017]$
重投影误差	0.4678332806984555

2.3 手部位姿估计

2.3.1 基于 MediaPipe Hands 的手部位姿估计方法

MediaPipe Hands 是一种轻量化、高效的实时手部跟踪解决方案，能够快速、准确地检测和追踪手部的 21 个关键点。该方法基于 MediaPipe 框架实现，框架结构主要包括两个核心模块：手部检测器和手部坐标预测模型。手部检测器负责从图像中快速定位手掌区域，而手部坐标预测模型则在检测到的手掌区域内精确定位手部关键点。这种模块化的设计使其在保证高精度的同时，显著提升了系统的实时性和计算效率，能够更好地适用于人机协作的场景。手部位姿估计实现框架如图 2-5 所示。




图 2-5 手部位姿估计实现框架

手部检测器是整个系统的核心模块之一，其主要作用是快速、准确地定位初始的手部位置，为后续的手部关节点提取提供基础。该模块的目标是输出一个包含整个手部的边界框，类似于传统目标检测任务。然而，手部检测面临着诸多挑战，例如手部尺寸跨度大、存在遮挡和自遮挡等情况。为了应对这些挑战，MediaPipe Hands 的手部检测器采用了多种优化策略：首先，考虑到包含较接手指的手的检测难度要远大于手掌和拳头等刚性物体，训练了一个手掌检测器来代替直接检测手部；其次，使用非极大值抑制算法，可以更好地应对存在遮挡的复杂场景；此外，检测器采用了与特征金字塔网络（FPN）结构相似

的特征提取模块，能够同时感知局部细节和全局上下文信息，进一步提升了检测性能；最后，在训练过程中使用了 Focal Loss 作为损失函数，通过降低易分类样本的权重，集中训练模型对难分类样本的学习，优化了检测器在高遮挡和尺寸变化情况下的性能。

在手部检测器完成手部检测后即可将手部区域提取出来，接着使用手部坐标预测模型对手部区域进行处理，手部坐标预测模型可以通过回归方法直接预测三维手部关节点坐标。手部坐标预测模型通过大量数据训练，学习到了内在的一致性手部姿态表示，显著提升了在部分区域缺失及自遮挡情况下的检测稳定性。最终该模型的输出包括了三个部分：手部关键点的三维坐标、输入图像中包含手部的置信度，以及用于区分左手或右手的二分类标签。

在 MediaPipe 手部跟踪系统中，为了优化计算效率并减少冗余计算，手掌检测器的运行频率被显著降低。具体而言，手掌检测器仅在必要时才会被触发运行，从而大幅减少了整体的计算时间。这一优化策略的核心在于利用当前帧中检测到的手部关键点信息，推断后续视频帧中手部的位置。通过这种方式，系统无需在每一帧上重新运行手掌检测器，从而显著提高了实时性和计算效率。为了确保系统的鲁棒性，手部追踪器模型额外输出一个标量值，用于表示手部存在且与输入裁剪图像对齐的置信度。该置信度反映了当前帧中手部关键点的可靠性。只有当置信度低于预设的特定阈值时，系统才会重新调用手掌检测模型对整个帧进行检测。这种机制不仅优化了计算资源的分配，还确保了在复杂场景或手部快速运动时，系统能够及时调整并维持高精度的跟踪效果。

2.3.2 手部关节点坐标检测实现

本研究中基于 MediaPipe 框架实现了手部关节点的三维坐标检测。通过该框架，能够精确地定位手部的 21 个关键点，这些关键点涵盖了手腕、手指关节以及指尖等重要部位，从而完整地描述了手部的姿态和形态。检测到的 21 个关节点位置如图 2-6 所示。




图 2-6 手部 21 个关节点位置示意图

通过 MediaPipe 框架，本研究实现了手部 21 个关节点的三维坐标检测。图 2-7 展示了手部关节点检测的可视化结果，包括手部边界框、关键点位置和

连接线。检测结果表明，该方法能够准确地定位手部的关键点，并且针对不同的手部姿态表现出较强的鲁棒性。从图中可以看出，手部的 21 个关键点被准确地标注出来，包括手腕、手指关节和指尖等重要部位。连接线清晰地展示了手指的骨骼结构，进一步验证了检测结果的准确性。



图 2-7 手部关节检测结果可视化

图 2-8 展示了手部关节点的三维坐标可视化结果，清晰地揭示了手部关节点的 X、Y、Z 坐标分布情况。这些坐标点的分布与手部的实际形态相吻合，验证了手部关节点三维坐标检测中的有效性。具体而言，X、Y 坐标系是基于相机视野的归一化坐标，原点设定在相机的左上角，坐标值域限定在 $[0, 1]$ 区间内，这一标准化过程反映了各个关节在图像中的位置。相对地，Z 轴坐标系以腕部关节为参照原点，通过仿射变换计算得到，该变换依据各个关节点相对于相机的距离而定。




图 2-8 手部关节点三维坐标可视化结果

值得注意的是，在图 2-8 中观察到的两种手腕部的 Z 轴坐标均位于 $Z=0$ 平面之上，这一结果实际上与手腕相对于相机的真实距离存在偏差。这种偏差

可能会对后续的动作识别任务造成一定影响。因此，为了提高动作识别的准确性和鲁棒性，需要对手部关节坐标进行进一步的优化，以确保 Z 轴坐标能够真实反映关节点与相机之间的距离关系。

2.3.3 融合深度信息的手部关节点坐标优化

针对 Z 坐标存在偏差的问题，本研究提出了一种融合深度相机捕获的深度信息的优化策略，旨在提高手部关节点坐标检测的准确性。具体来说，本研究采用了 Azure Kinect DK 设备自带的基于深度信息的人体骨骼关节点跟踪模块，利用其捕获的腕部关节深度信息以及之前标定得到的相机内参对识别出的 21 个手部关节点进行坐标优化。之所以没有直接该模块进行手部关节点提取，是因为该模块主要是针对整个人体进行关节点提取，对于手部能识别的关节点个数十分有限，不利于后续细粒度的手部动作识别。该模块能够提供精确的深度数据，这些数据对于优化手部关节点的三维坐标至关重要。

在使用人体跟踪模块之前，需要明确从 Azure Kinect DK 使用人体跟踪模块捕获的关节点坐标 X、Y、Z 分别代表的内涵。Azure Kinect DK 的人体跟踪模块使用相机坐标系，其原点表示相机的光心（即深度摄像头的中心），X 轴表示相机的水平方向，向右为正方向，Y 轴表示相机的垂直方向，向上为正方向，Z 轴代表深度方向，向前为正方向，输出的结果以 mm 为单位。

融合深度信息的手部关节点坐标优化具体过程如下：

（1）信息捕获：启动设备时同时开启 Azure Kinect DK 的 RGB 摄像头以及深度摄像头，获取 RGB 视频流及深度视频流。

（2）手部关节点提取：使用 MediaPipe 获取左右手 21 个手部关节点的相对坐标，使用 Azure Kinect DK 自带的人体跟踪模块实现人体关节点跟踪。

（3）关节点坐标优化：提取人体跟踪模块获取的左右手腕部关节点的深度信息，即对应的 z 坐标，利用深度信息以及相机内参对 MediaPipe 检测到的每个关节点进行坐标转换，最终得到在相机坐标系中的手部关节点坐标。

以左手为例，上述过程中的坐标转换公式如下：

$$\begin{cases} z_i = d_l + \frac{z_i^m(d_l + d_r)}{2} \\ x_i = \frac{(x_i^m w - c_x)z_i}{f_x} \\ y_i = \frac{(y_i^m w - c_y)z_i}{f_y} \end{cases} \quad (2-12)$$

其中， (x_i, y_i, z_i) 表示第 i 个关节点坐标转换后的坐标点，单位为 mm； (x_i^m, y_i^m, z_i^m) 表示使用 MediaPipe 检测到的第 i 个关节点的坐标，单位为 1； d_l

和 d_r 分别表示左手手腕和右手手腕的深度信息，单位为 mm； f_x, f_y 分别表示相机在 x 和 y 方向上的焦距，以像素为单位； (c_x, c_y) 为成像平面图像中心点的像素坐标。 f_x, f_y, c_x, c_y 在上一小节的相机标定结果中获取。




图 2-9 深度相机和 RGB 相机效果图对比

基于深度信息的人体关节点跟踪效果以及基于 RGB 的手部关节点跟踪效果如图 2-9 所示。其中 RGB 相机使用了 K4A_COLOR_RESOLUTION_720P 模式，表示使用了 1280x720 分辨率，其视野角度水平方向为 90° ，垂直方向为 59° ；深度相机使用了 K4A_DEPTH_MODE_WFOV_2X2BINNED 模式，表示将深度相机的模式设置为宽视野(WFOV)，2x2 像素合并，分辨率为 512x512，宽视野的视野角度水平方向为 120° ，垂直方向为 120° ，该模式比较适合近距离的深度估计，可以在较近的距离内捕获较多的人体骨架信息。由于相机的可视范围存在差异，所以展示出来的图像也相对的存在差异。




图 2-10 变换前后手部关节点三维空间可视化

如图 2-10 所示，为变换前后手部关节点三维空间可视化。变换前的 x 、 y 、 z 轴分别表示在图像的宽度维度归一化表示、在图像的高度维度的归一化表示、以腕部为原点经过仿射变换的相对相机距离；变换后的 x 、 y 、 z 轴坐标表示手部关节点在相机坐标系中的坐标，其中 z 表示关节点与相机的距离，单位均为

mm。通过对比变换前后的关节点分布,可以明显看出,变换后的手部关节点在三维空间中的定位更加精确,与实际手部形态的一致性得到了显著提升。变换后的手部关节点坐标在 Z 轴上的深度信息更加贴近实际距离,这一点对于后续的动作识别和手势分析至关重要,因为准确的深度信息能够帮助区分不同手势之间细微的姿态差异,从而提高识别的准确率和鲁棒性。

通过这种方法,能够显著提高手部关节点坐标检测的准确性,尤其是在代表深度的 Z 轴方向上。这不仅使得关节点的三维分布更加符合实际情况,而且为后续的动作识别和手势分析提供了更可靠的数据基础。

2.4 本章小结

本章系统研究了基于视觉的动作感知与数据获取方法,主要工作包括:(1)建立了基于张友正标定法的相机标定系统,通过分析相机成像模型和标定板特征点,完成了相机标定工作并获取了相机内参,为后续工作提供了相机内参用于校正关节点坐标;(2)搭建了基于 MediaPipe Hands 框架的手部位姿估计方案,实现了 21 个手部关键点的实时检测,并且展示了手部关节点在三维空间可视化的结果;(3)引入深度信息和相机内参对手部关节点坐标进行优化,显著提升了复杂装配场景下的位姿估计鲁棒性,为后续章节的动作识别与预测研究奠定了数据基础。

第 3 章 多模态数据驱动的装配动作识别方法研究

3.1 引言

装配动作识别是人机协作中的重要任务，旨在从视频或传感器数据中准确识别人类执行的装配动作，从而为机器人提供实时的动作理解与反馈。传统基于单一模态的方法往往因信息表征不完整而导致识别精度受限。为了克服单一模态方法的局限性，本章旨在研究一种多模态数据驱动的装配动作识别方法，通过融合 RGB 图像和手部关节点数据，构建一个高效准确的动作识别网络。该方法通过融合 RGB 图像特征和手部关节点特征，旨在充分利用多模态数据的互补性，在保证识别精度的同时提升推理效率，从而为复杂装配场景下的动作识别提供一种高效且鲁棒的解决方案。

3.2 动作识别公开数据集

在动作识别与预测领域，研究者们广泛使用多个公开数据集来训练和评估模型，其中包括 EPIC-KITCHENS、50Salads、Breakfast、Meccano、IKEA-ASM 以及 Assembly101 等。这些数据集在规模、场景覆盖、标注粒度等方面各有特点，适用于不同的研究任务。表 3-1 对这些数据集进行了详细对比。

表 3-1 动作识别公开数据集对比

数据集	视频 总时长	视频 总个数	片段 总个数	动词 类别	名词 类别	动作 类别
EPIC-KITCHENS	100.0	700	89977	97	300	4053
50Salads	4.5	50	899	6	15	17
Breakfast	77.0	1712	11300	14	28	48
Meccano	6.9	20	8858	12	21	61
IKEA-ASM	35.0	371	17577	12	10	33
Assembly101	513	4321	1013523	24	90	1380

EPIC-KITCHENS 和 Breakfast 是视频理解领域中数据规模相对较大且标注较为丰富的代表性数据集，然而这些数据集中的动作多集中于家居生活场景，与人机协作装配场景的关联性较弱，难以直接应用于工业装配或协作机器人领域的动作识别与预测任务。相比之下，Meccano 和 IKEA-ASM 数据集则专注于工业装配场景，提供了与装配任务相关的动作数据。Meccano 记录了机械装配过程中的精细动作，而 IKEA-ASM 则聚焦于家具组装任务。尽管这些数据集在场景上与工业装配任务高度契合，但其数据规模相对较小，类别多样性有限，难以支持复杂模型的训练与验证。相比之下，Assembly101 数据集以其大

规模性、多模态性和精细的动作标注脱颖而出。该数据集专注于玩具车的组装与拆卸任务，涵盖了丰富的装配动作类别，且每个动作标签均由动词和名词构成的词组表示，类别丰富且具有详尽的标注。因此，Assembly101 数据集十分适合用于本研究中模型的有效性验证，其数据结构也可作为后续实验的参考。

Assembly101 数据集是一个专门针对不同种类玩具车组装与拆卸任务的大规模数据集，其数据规模和标注丰富度使其成为动作识别与预测任务的理想选择。该数据集包含来自 8 个静态视角和 4 个以自我为中心视角的录像，总计 4321 个视频序列，视频总时长达到 513 小时，涵盖了大量的装配动作样本，序列注释包括超过 10 万个粗粒度动作片段和 100 万个细粒度动作片段，以及 1800 万个 3D 手部姿势。该数据集提供了多种模态的数据形式，包括：高分辨率（ 1920×1080 ）的 RGB 视频，帧率为 60FPS，用于记录装配任务的视觉信息；分辨率 640×480 的深度图像，用于提供装配场景的三维空间信息；左右手部关节点数据，每只手 21 个关节点的三维坐标（ x, y, z ），能够精确描述手部姿态和运动轨迹。在动作类别方面，Assembly101 定义了 15 个玩具车类别，定义了 90 个对象，包括轮子、车体等零件，以及 5 种工具和“手”这一特殊对象，指定了 24 个交互动词，如“拿起”、“拧紧”、“放置”等。对象和交互动词共同形成了 1380 个细粒度的动作标签。

Assembly101 数据集提供了精细的动作标注，标注形式包括动作类别标签、时间戳标签以及手部姿态标签。动作类别标签即每个动作被标注为一个具体的类别标签，形式为由动词和名词构成的词组。如“拿起螺丝刀”、“拧紧螺丝”、“放置零件”、“拆卸组件”等，这种标签形式能够清晰地描述装配任务中的具体操作，便于模型学习动作的语义信息。时间戳标签即每个动作的开始时间和结束时间的精确标注，能够支持时间序列分析，便于模型学习动作的时序特征。手部姿态标签记录了在 60FPS 下每一帧每只手 21 个关节点的三维坐标（ x, y, z ），能够精确描述手部在动作执行过程中的姿态变化。




图 3-1 Assembly101 提供的数据及标注^[46]

在本研究中，Assembly101 数据集被用于训练和评估基于 Transformer 的

装配动作识别模型。通过利用数据集提供的 RGB 视频和手部关节点数据，本研究构建了一个多模态融合的动作识别网络，旨在充分利用不同模态数据的互补性，提升动作识别的精度和效率。

3.3 结合 RGB 和手部关节点特征的动作识别网络

3.3.1 动作识别网络整体概述

本文采用了一种结合 RGB 图像和手部关节点特征的多模态动作识别网络。该网络旨在通过融合视觉外观信息和手部运动信息来提高动作识别的准确性。图 3-2 所示为该动作识别网络的整体框架。




图 3-2 动作识别网络整体框架

具体而言，网络首先将连续动作序列分解为若干微动作单元，每个单元包含单帧 RGB 图像和对应的多帧手部关节点序列。在特征提取阶段，RGB 特征提取模块利用 TSM-ResNet50 网络从图像中提取空间视觉特征；同时，手部关节点特征提取模块采用基于 MS-TCN 的网络架构，从时序维度捕捉手部关节点的运动轨迹特征。最后，通过模态共融模块，将两种异构模态的特征进行深度融合，并引入时序 Transformer 对序列化特征进行建模，最终通过多层感知机（MLP）输出动作分类结果。这种多模态融合策略能够有效克服单一模态信息不足的缺陷，从而提升动作识别的准确性和鲁棒性。

3.3.2 数据前处理模块

给定一个以某种帧率采样的包含 T 帧视频帧的动作片段，模型的输入包括：

- （1）一个密集的 3D 手部姿势序列，可以表示为 $S = \{P_1, P_2, \dots, P_T\}$ ，其中

$P_t = \{P_{left,t}, P_{right,t}\} \in R^{2 \times J \times 3}$ ，表示左右手的 J 个关键点的 3D 坐标

(2) 一个稀疏的 RGB 帧序列，按照采样间隔为 Δf 进行采样，可以表示为 $V = \{I_1, I_{1+\Delta f}, \dots, I_{T_r}\}$ ，其中 $I_t \in R^{H \times W \times 3}$ 表示逐帧的 RGB 图像输入，且 $T_r = 1 + \left\lfloor \frac{T-1}{\Delta f} \right\rfloor \times \Delta f$ 。

在本研究中，将原始输入划分为长度为 N 帧的 K 个微动作块，通过以 R 帧为步长在动作片段上进行滑动窗口来获得。每个微动作块包含两个部分，即来自块内的第一个 RGB 帧以及由 N 帧密集姿态序列表示的手部关节运动。为了获得固定长度的输入，对于 $T' = (K-1) \times R + N$ 帧的姿势序列，需要对每个关节沿着时间轴进行线性插值，将具有 T 帧的姿势序列 S 转换为具有 T' 帧的 $S' = \{P'_1, P'_2, \dots, P'_{T'}\}$ ，其中， $P'_t \in R^{2 \times J \times 3}$ 。由此，输入被表示为了一个由稀疏的 RGB 帧序列 V 和转换后的多帧密集姿态序列 S' 组成的微动作序列 $M = \{M_1, M_2, \dots, M_K\}$ ，可以通过以下公式表示：

$$M_k = [M_k^{RGB}, M_k^{Pose}] = [I_{h(k)}, \{P'_{g(k)+i}\}_{i=0}^{N-1}] \quad (3-1)$$

其中 $g(k) = (k-1) \times R + 1$ 表示第 k 个微动作的第一个姿势帧，而 $h(k)$ 为 RGB 帧的索引。密集的姿势序列捕捉了细粒度的手部运动，这对于动作识别至关重要，而单个 RGB 帧提供了识别可操作对象的语义上下文。为了从微动作中提取特征，本研究使用了 RGB 特征提取器 F_R 和关节运动特征提取器 F_P ，它们分别对 RGB 帧和手部姿态序列进行特征提取。因此，第 k 个微动作的 RGB 和姿势特征分别为：

$$[f_k^{RGB}, f_k^{Pose}] = [F_R(M_k^{RGB}), F_P(M_k^{Pose})] \quad (3-2)$$

其中， $f_k^{RGB}, f_k^{Pose} \in R^d$ ， d 表示 RGB 和姿势嵌入空间的共同维度。

3.3.3 基于 TSM-ResNet50 的 RGB 特征提取模块

在动作识别任务中，RGB 图像序列提供了丰富的视觉外观信息，能够有效捕捉动作的时空特征。为从 RGB 视频序列中提取这些特征，本文采用基于时序移位模块 (Temporal Shift Module, TSM) 的 ResNet50 网络作为 RGB 特征提取模块。TSM-ResNet50 结合 ResNet50 强大的空间特征提取能力和 TSM 的时间建模能力，在保持高效计算的同时，能够充分捕捉视频序列中的时序信息。

ResNet 是一种经典的深度残差网络，通过引入残差连接缓解了深层网络中的梯度消失问题，使得网络能够训练得更深，从而提取到更丰富的特征。ResNet50 的网络结构包含四个主要部分：输入图像首先经过 7×7 卷积层，配合批量归一化和 ReLU 激活函数进行初步特征提取，再通过最大池化层下采样；随后是核心的四个残差块阶段，分别包含 3、4、6、3 个残差块，每个块采用 1×1 、 3×3 、 1×1 的卷积组合来优化特征表达；接着通过全局平均池化

将特征压缩为 1×1 向量；最后使用全连接层输出分类结果。这种结构通过残差连接有效解决了深层网络的梯度消失问题。

TSM 是一种轻量级的时间建模模块，能够在 2D 卷积神经网络中引入时间维度信息，而无需增加额外的参数量或计算复杂度。TSM 的核心思想是通过在特征图的通道维度上进行时间移位（temporal shift），将相邻帧的特征信息融合到当前帧中。具体来说，TSM 将输入特征图的一部分通道沿着时间轴向前或向后移动，从而在时间维度上引入上下文信息。图 3-3 所示为 TSM 进行的移位操作示意图。




图 3-3 TSM 移位操作示意图

TSM 的优势在于它能够在 2D 卷积的基础上实现时间建模，避免了使用 3D 卷积带来的高计算成本，这使得 TSM 非常适合用于处理长视频序列的动作识别任务。如图 3-4 所示为 TSM 插入前后的残差块，TSM 能够很方便地插入 ResNet 的残差块中，且几乎不需要增加额外的计算成本。




图 3-4 TSM 插入前后的残差块

在本文的架构中，ResNet50 作为骨干网络负责从每一帧中提取空间特征，

而 TSM 模块则被插入到 ResNet50 的残差块中,使网络能够在提取空间特征的同时捕捉时间上的动态变化。如图 3-5 所示的 TSM-ResNet50 网络示意图。




图 3-5 基于 TSM-ResNet50 的 RGB 特征提取模块示意图

在本文的动作识别网络中, TSM-ResNet50 被用作 RGB 特征提取模块。其具体流程如下:

(1) 输入预处理: 输入为一段 RGB 视频序列, 从中视频序列中等间隔抽取若干帧图像, 接着将图像批量调整为固定的分辨率 (如 224×224), 在训练过程中还需要增加一些数据增强方法, 再将其归一化到 $[0, 1]$ 范围。

(2) 初始卷积层: 输入数据首先通过一个 7×7 的卷积层 (Conv 7×7), 这一层用于提取图像的初步特征。接着通过 ReLU 激活函数引入非线性, 增强模型的表达能力。然后, 通过最大池化 (MaxPool) 层进行下采样, 对数据进行降维, 保留重要的特征信息。

(3) 残差时间分离模块 (Residual-TSM): 在 ResNet50 的每个残差块中插入 TSM 模块。TSM 模块通过对特征图的通道进行时间移位, 将相邻帧的特征信息融合到当前帧中。具体来说, 对于每个残差块, 输入特征图的一部分通道会沿着时间轴向前或向后移动, 从而引入时间上下文信息。经过 TSM 模块处理后, ResNet50 的卷积层会逐层提取视频帧的空间特征, 同时 TSM 模块会

在时间维度上融合相邻帧的信息，从而捕捉到视频序列中的时空特征。

(4) 特征输出：在经过多个残差块和 TSM 模块的处理后，网络通过全局平均池化层将特征图的空间维度降为 1×1 ，得到一个固定长度的特征向量。该特征向量包含了视频序列的时空特征信息，将作为 RGB 模态的特征输出。

在训练整个动作识别网络之前，需要先单独对 TSM-ResNet50 进行预训练。TSM-ResNet50 的训练过程通常采用预训练的 ResNet50 权重进行初始化，以加速收敛并提高模型的泛化能力。训练时，视频序列会被分割成固定长度的片段（如 8 帧），每个片段作为一个输入样本。通过数据增强技术（如随机裁剪、水平翻转等），可以进一步提高模型的鲁棒性。在预训练阶段，需要以动作类别作为目标，降低分类的损失，得到一个最优的训练权重。在训练整个动作分类网络之前，需要使用预训练好的权重对 TSM-ResNet50 模块进行初始化，TSM-ResNet50 会对整个视频序列进行分段处理，每个片段的特征向量会被提取并用于后续的模式融合模块。

基于 TSM-ResNet50 的 RGB 特征提取模块通过结合 TSM 的时间建模能力和 ResNet50 的空间特征提取能力，能够有效地从 RGB 视频序列中提取时空特征。该模块为后续的模式融合和动作识别提供了丰富的视觉外观信息，是本章动作识别网络的重要组成部分。

3.3.4 基于 MS-TCN 的关节运动特征提取模块

在手部动作识别与分析领域，手部关节运动特征的提取是实现精准动作识别的关键环节。传统方法在处理手部关节运动时，往往难以有效捕捉其复杂的时空动态特性，尤其是在面对快速动作或微小变化时，特征提取的准确性和鲁棒性受到限制。因此，本研究采用了一种基于多尺度时间卷积网络（Multi-Scale Temporal Convolutional Network, MS-TCN）的方法来提取手部关节的运动特征，MS-TCN 作为一种高效的时序建模工具，能够有效地捕捉手部关节的运动轨迹和动态变化。通过引入 MS-TCN，能够在保证计算效率的同时，提取出更具判别性的手部运动特征。

MS-TCN 是一种基于多阶段时间卷积网络（TCN）的时序数据处理架构，其核心创新在于通过级联的扩张卷积阶段实现渐进式特征优化。该架构采用具有不同膨胀率的扩张卷积层来捕获多尺度时序特征，配合跨阶段残差连接机制，既有效扩展了时间感受野又缓解了梯度消失问题。相较于传统 RNN/LSTM 模型，MS-TCN 通过并行卷积运算显著提升了计算效率，同时保持了对长程时序依赖的高分辨率建模能力，在特征提取精度和计算性能上均展现出明显优势。

此外，本研究还使用了腕部关节的运动作为全局运动参考。网络中存在

两种 MS-TCN，单关节 MS-TCN 是一个时间卷积网络，对所有关节的轨迹分别进行处理，并在所有关节之间共享参数，腕部 MS-TCN 对整个动作期间的手腕位置和手部方向序列进行处理，并生成一个全局参考标记，之后对这个标记经过不同的线性层，插入到不同尺度的单关节特征中，并经过自注意力层，保留时间维度以供后续阶段使用。经过这一迭代过程最终能够总结出微动作中的手部运动。

在本文的架构中，一种基于 MS-TCN 的方法被用于提取手部关节的运动特征，该模块的示意图如图 3-6 所示。




图 3-6 基于 MS-TCN 的手部关节运动特征提取模块示意图

手部关节运动特征提取过程可以概括为以下几个主要步骤：

（1）输入与预处理：输入数据首先提取出腕部关节运动数据，腕部关节数据 and 原始输入数据都需要经过批归一化（BN）层，标准化输入特征，减少内部协变量偏移，加速训练过程并提高模型的稳定性，接着在分别输入腕部 MS-TCN 和单关节 MS-TCN 进行下一步的特征提取。

（2）MS-TCN 模块：MS-TCN 模块是特征提取的核心，它由多个时间卷积网络（TCN）层组成，每个 TCN 层后接一个批归一化层和 ReLU 激活函数，以增强模型的非线性表达能力。本文中的 TCN 层包含两种膨胀率的 3x3 卷积，旨在捕获不同时间尺度上的特征，并通过并行处理和特征融合提高特征提取的效率和准确性。

（3）特征融合与自注意力机制：在 MS-TCN 模块之后，提取的特征通过自注意力（Self-Attention）机制进行进一步处理。自注意力机制能够捕捉特征之间的长距离依赖关系，多个自注意力层的堆叠，这有助于逐步细化特征表示，

提高特征的区分度。

(4) 特征输出：在经过自注意力层完成特征融合之后，最终可以输出一个固定长度的特征向量，该特征向量包含了手部骨骼关节点的运动特征信息，将该特征向量输出即可。

综上所述，基于 MS-TCN 的手部关节点运动特征提取过程通过一系列精心设计的网络结构和处理步骤，能对手部关节点运动特征的高效、准确提取，最终输出的手部关节点运动特征能够有效捕捉手部动作的复杂模式和时间依赖性，为后续的手部动作识别任务提供了高质量的特征表示。

3.3.5 多模态特征融合模块

本节介绍模态融合模块的设计，该模块旨在有效地整合来自不同模态的特征，以提升模型的性能。模态融合模块的核心思想是通过线性变换和多层感知机（MLP）来融合 RGB 特征和关节点运动特征。




图 3-7 模态融合模块

如图 3-7 所示，模态融合模块主要由以下几部分组成：

- (1) 特征线性变换：对于 RGB 特征和关节点特征，首先分别通过线性层（Linear）进行变换，以调整特征维度并进行初步的特征提取。
- (2) 特征拼接：将线性变换后的 RGB 特征和关节点特征进行拼接（Concat），拼接后特征维度变为原来的两倍长，形成融合了两种模态信息的特征表示。
- (3) 多层感知机处理：为了进一步提取和融合特征，分别让拼接前的 RGB 特征、关节点特征以及拼接后的多模态特征经过多层感知机（MLP）投影到共享的特征空间，由此得到三组新的特征。MLP 能够学习到特征之间的复杂关

系，提高特征的表达能力。

(4) 特征融合：为了保证特征维度的统一，经过 MLP 处理后的 RGB 特征、关节点特征再次进行拼接（Concat），再将拼接后的特征与经过 MLP 处理后的融合特征相加得到最终的特征表示。

通过结合 RGB 图像的视觉信息和关节点的时空信息，模态融合模块能够提供更全面的动作表示，有助于提高动作识别的准确性。RGB 特征和关节点特征在动作识别中具有互补性。RGB 特征能够捕捉动作的视觉外观，而关节点特征能够提供动作的时空结构信息。通过融合这两种特征，可以更好地理解动作的本质。多模态特征融合还有助于提高模型对噪声和遮挡的鲁棒性。即使某一模态的特征受到干扰，另一模态的特征仍然可以提供有用的信息，从而提高整体的识别性能。

3.3.6 时序 Transformer 模块

本节介绍时序 Transformer 模块，时序 Transformer 模块是用于处理时间序列数据的关键组件，它负责处理经过模态融合后的多模态特征，并最终输出动作分类结果。该模块可以捕获时间序列中的长程依赖关系，这对于理解视频动作片段中的动作模式尤为关键。




图 3-8 时序 Transformer 模块

如图 3-8 所示，时序 Transformer 模块通过嵌入层和位置编码将输入序列转换为包含位置信息的高维向量表示，其核心组件自注意力机制能有效捕捉动作序列中的长程依赖关系和关键帧特征。模块采用层归一化(LN)来稳定训练过程，并通过前馈神经网络(FFN)实现特征的非线性转换，各子层均采用残差连

接以促进梯度传播并缓解梯度消失问题,从而构建了一个高效处理时序数据的深度学习架构。

模态融合模块为每个微动作提供完成模态共融后的 RGB 特征和关节点运动特征。由于动作片段由一系列微动作组成,这些微动作特征通过时序 Transformer 在时间上进行聚合。一个视频 V 被划分为 K 个微动作,可以通过由模态融合模块生成的两组特征 $\{\hat{f}_k^{\text{RGB}}\}_{k=1}^K$ 、和 $\{\hat{f}_k^{\text{Pose}}\}_{k=1}^K$ 分别表示。这 $2 \times K$ 个特征的维度为 d , 形成了时序 Transformer 的输入序列。接着为每个输入添加位置编码和模态嵌入,以指示时间位置和源模态。本文使用固定的正弦/余弦位置编码,为来自相同微动作的两个特征分配相同的位置编码。模态嵌入是可学习的,并在相同模态 (RGB 或者关节点) 的特征之间共享。此外,按照标准做法,还需要在输入序列的开头添加一个额外的可学习类别标记,其他输出将用于动作分类。

时序 Transformer 模块通过自注意力机制、层归一化、前馈神经网络和残差连接等组件,能够实现对时间序列数据的高效处理和特征提取。该模块能够有效捕捉时间序列数据中的长程依赖关系,这对于动作识别等任务至关重要。且与传统的循环神经网络 (RNN) 相比,Transformer 模块可以并行处理序列中的所有元素,大大加快了训练速度。

3.3.7 学习目标

本研究中的动作识别网络使用了一种综合性的目标函数,旨在通过端到端的训练方式,优化动作识别的性能。利用交叉熵损失函数进行动作分类的监督学习,同时引入了特征预测损失来增强模型对动作序列的理解。

交叉熵损失函数 L_{cls} 用于监督模型的动作分类任务,其表达式为:

$$L_{\text{cls}} = - \sum_i a_i \log \hat{a}_i \quad (3-3)$$

其中, a_i 表示第 i 个样本的真实动作标签,而 $\hat{a}_i$ 表示模型预测的动作类别。该损失函数确保模型能够准确识别动作类别。

为了更有效地利用输入的姿势和 RGB 模态提供的互补信息,本文还引入了两个额外的可学习类别标记,用于对显示的动词和可交互物体的名词进行监督学习。动词类别标记专注于姿势编码,而名词类别标记则专注于 RGB 特征。这种设计使得模型能够分别捕捉动作的运动 (L_{verb}) 和交互物体 (L_{noun}),从而提高整个动作识别的准确性。

此外,学习目标还使用了特征预测损失 L_{ant} 用于捕捉手部-物体交互过程中主要的状态变化。假设初始 RGB 帧的视觉状态与后续手部姿势序列相结合,可以指示该序列完成后的视觉状态。因此,给定一个微动作中的 RGB 特征和相

应的姿势特征，让模型通过最小化特征预测损失来预测下一个微动作的 RGB 特征，接着通过比较可以量化预测的图像特征与从冻结的 RGB 特征提取器中提取到的真实特征之间的差异。这一损失的表达式为：

$$L_{\text{ant}} = \sum_{k=1}^{K-1} \|\phi_{\text{ant}}(f_k^{\text{PoseRGB}} - f_{k+1}^{\text{RGB}})\| \quad (3-4)$$

其中， ϕ_{ant} 表示一个线性投影层。这种损失有助于模型学习到动作序列中的视觉变化，从而提高对动作变化的理解。

总损失函数 L 是上述四种损失函数的加权和，其表达式为：

$$L = L_{\text{cls}} + \lambda_1 L_{\text{verb}} + \lambda_2 L_{\text{noun}} + \lambda_3 L_{\text{ant}} \quad (3-5)$$

其中， $\lambda_1, \lambda_2, \lambda_3$ 是用于平衡四种损失的超参数。这种设计确保了模型在动作分类、动词和名词识别以及特征预测方面的综合性能。

通过综合动作分类、动词和名词以及特征预测损失，本研究中的动作识别网络的学习目标旨在提高模型在动作识别任务中的准确性和鲁棒性。这种多任务学习方法能够有效地整合来自不同模态的信息，进一步提升模型在动作识别任务中的表现。

3.4 基于公开数据集的模型性能评估

3.4.1 实验环境与评价指标

本研究中的动作识别算法采用 Python 语言实现，并基于 PyTorch 框架构建整个网络。表 3-2 展示了本文中使用的核心 Python 包及其版本的详细信息。

表 3-2 实验环境主要软件及版本配置表

包名	版本
python	3.8
CUDA	12.1
cuDNN	8.9.0
torch	2.3.1
torchvision	0.14.1
tensorboard	2.11.2
opencv-python	4.7.0
decord	0.6.0
numpy	1.23.5
pandas	1.5.2

硬件方面，实验使用了 Ubuntu20.04 系统电脑，配备有 Intel i7-13700F 处理器、NVIDIA RTX3060 显卡以及 32G 内存。软件环境方面，在 Anaconda 环境中配置了 Python 3.8 版本，并安装了 gpu 版本的 PyTorch 及其配套的 torchvision 库，tensorboard 用于记录训练过程中的各种数据变化。此外，实验还使用到了 OpenCV 及 decord 库用于视频帧的提取以及视频前处理工作，Numpy 和 Pandas 库则用于数据处理。

动作识别本质上是一个多分类问题，在本研究中，为了定量评估动作识别算法的性能，我们选择了准确率（Accuracy）作为主要的评价指标。准确率是最直观且广泛使用的分类性能度量标准之一，它能够直接反映模型在识别任务中的总体表现。准确率的计算基于混淆矩阵，如表 3-3 所示。

表 3-3 混淆矩阵

混淆矩阵		预测值	
		1	0
真实值	1	TP（真正例）	FN（假负例）
	0	FP（假正例）	TN（真负例）

准确率（Accuracy）可以定义为分类正确的样本数与所有需要分类的样本总数的比值，可以反应模型的分类性能和泛化能力，其计算公式如下：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3-6)$$

其中，TP（真正例）表示正类样本的正确识别数；TN（真负例）表示负类样本的正确判别数；FP（假正例）反映负类误判为正类的数量；FN（假负例）则反映正类误判为负类的数量。

准确率的取值范围在 0 到 1 之间，1 表示模型的预测完全正确，而 0 则表示模型的预测完全不准确。在动作识别任务中，一个高准确率的模型意味着它能够从输入数据中正确识别出动作类别，这对于实际应用来说至关重要。

3.4.2 基于 RGB 特征的动作识别网络实验评估

本小节旨在通过公开数据集 Assembly101 对基于 RGB 特征的动作识别网络进行实验评估。该网络以 TSM-ResNet50 架构为基础，训练目标为最小化分类损失函数。Assembly101 数据集是一个多视角视频数据集，鉴于本研究聚焦于固定单视角的动作识别任务，以及对全视角数据进行训练的计算成本较高，本研究仅选取了 Assembly101 数据集的 v1 视角数据进行实验。在该视角下，训练集样本数量为 44,460，测试集样本数量为 14,484，动作类别总数为 1,380。

在本研究中，为了确保视频数据能够适配模型输入要求，同时增强数据的

多样性和模型的泛化能力,需要对视频数据进行统一的预处理。具体步骤如下:首先,从原始视频中按照固定时间间隔均匀抽取帧序列,以构建时间维度上的代表性样本。随后,将抽取的帧图像统一缩放至指定尺寸(224×224 像素),并采用随机裁剪、随机水平翻转以及随机垂直翻转等数据增强技术,进一步丰富数据的多样性。为确保输入数据的数值范围一致性,还需对图像进行归一化处理,将像素值缩放至[0, 1]区间。通过上述步骤,完成了数据的预处理工作。

将经过一系列预处理步骤得到的图像特征序列输入至基于 ImageNet 预训练的时移模块网络(TSM)模型,选择以 ResNet50 作为基础架构。在训练过程中,采用批量大小为 16 的设置,并将每个视频均匀划分为固定数量的子片段,从每个子片段中抽取一帧图像作为输入特征。本研究中,每段视频被划分为 8 个子片段,即每个视频序列抽取 8 帧图像用于模型输入。训练周期设定为 50 个 epoch,优化器选用随机梯度下降(SGD)算法,其中动量参数(momentum)设置为 0.9,权重衰减(weight decay)参数设置为 0.0005,初始学习率设定为 0.001。权重衰减的设置旨在通过正则化手段防止模型过拟合,从而确保模型在训练过程中的泛化能力。此外,学习率采用分段常数衰减策略,分别在第 20 个和第 40 个训练周期降低学习率,以进一步优化模型性能。时移模块的划分参数(shift div)设置为 8,即特征通道被划分为 8 份,分别进行时间维度上的前移和后移操作。具体的训练参数设置如表 3-4 所示。

表 3-4 训练参数设置

参数名称	参数值
训练样本数	44460
动作类别数	1380
批量大小	16
输入尺寸	224
帧数	8
时移分割比	8
训练轮数	50
优化器	随机梯度下降
学习率	0.001
权重衰减	0.0005
动量	0.9
损失函数	交叉熵损失

训练过程中,使用 tensorboard 分别记录了训练中学习率、损失、准确率的变化情况。学习率变化曲线如图 3-9 所示,损失变化曲线如图 3-10 所示,准确率变化曲线如图 3-11 所示。

图 3-9 展示了模型训练过程中学习率的变化情况。初始阶段，学习率保持在 0.01 的水平，模型在训练初期采用了较高的学习率以快速收敛。在第 20 个 epoch 时，学习率显著下降至 0.001，在第 40 个 epoch 时，学习率再次下降至 0.0001，这主要是为了在训练后期细化模型参数，避免过大的学习率导致模型在最优解附近震荡。学习率发生变化时，损失和准确率也同样发生了较明显的变化，说明了学习率调度策略有效性。




图 3-9 学习率变化曲线




图 3-10 损失变化曲线




图 3-11 准确率变化曲线

图 3-10 展示了模型训练过程中损失函数值的变化趋势。可以观察到，损

失函数值在训练初期迅速下降,从初始的 5 左右降至接近 3,这一阶段模型学习速度较快,能够迅速减少预测误差。然而,在第 20 个 epoch 之后,损失函数值的下降速度明显放缓,最终在第 50 个 epoch 时稳定在 2 左右。这表明模型在训练后期逐渐收敛,损失函数值趋于稳定。损失函数值的下降趋势表明模型在训练过程中逐渐学习到了数据的内在规律,预测误差不断减少。

图 3-11 展示了模型训练过程中准确率的变化情况。从图中可以看出,模型的准确率在训练初期迅速上升,从 10%左右提升至 30%左右。在第 20 个 epoch 之后,准确率的提升速度有所放缓,但在第 50 个 epoch 时,准确率已经稳定在 38%左右。准确率的提升趋势表明模型的能力得到了持续增强,尽管在训练后期提升速度有所放缓,但整体上模型的性能得到了显著提升。

3.4.3 基于手部关节点的动作识别网络实验评估

本小节旨在通过公开数据集 Assembly101 对基于手部关节点特征的动作识别网络进行实验评估。该网络的核心是使用 MS-TCN 模块进行时序特征提取,并且使用腕部关节点的运动作为全局运动参考,使用两种 MS-TCN 分别对腕部运动轨迹及所有关节点的轨迹进行特征提取,最终总结出整个动作中的手部运动特征。实验过程中使用到的数据同上一节一致。

针对骨骼关节点数据的时间序列特性,本文采用了一种基于裁剪与插值的策略进行数据预处理,旨在通过随机裁剪和时间维度插值的方式,实现数据的标准化与增强,以满足模型对输入数据的固定长度要求,并提升模型对时间序列变化的鲁棒性。具体而言,首先对原始动作数据的时间序列根据预设的时序维度裁剪比例区间[0.7, 1.0]进行随机裁剪,通过裁剪比例参数引入了随机性,可以模拟实际场景中数据片段的不完整性,同时增强数据的多样性,为模型训练提供了更丰富的样本。随后,基于裁剪后的帧索引,从原始动作数据中提取对应的帧,并将其存储于一个临时数组中。为了进一步将时间序列调整为指定目标长度,还需要对时间维度进行插值调整。本文利用了双线性插值算法,对时间序列进行上采样或下采样,以确保最终输出数据的时间维度与模型输入要求一致,不仅实现了时间序列的标准化,还通过引入平滑的时间变化,增强了模型对时间序列变化的适应能力。通过上述步骤,完成了数据的预处理工作。

将经过预处理的骨骼关节点序列输入到动作网络中开始模型的训练与测试。在本研究中,模型训练过程的参数设置旨在优化网络性能并确保训练的高效性与稳定性。表 3-5 展示了具体参数配置。训练样本总数为 44460,涵盖 1380 个动作类别,每个动作由双手 21 个关节数和 120 个时间步长的动作数据表示。训练过程中采用 32 的批量大小,以平衡计算效率与内存占用。为防止过拟合,

模型中设置 0.2 的 Dropout 比例。此外,注意力机制中每个头的维度设置为 4,以适应动作数据的特征规模。在模型架构方面,时间卷积网络(TCN)的卷积核大小为 3,步幅依次为 [1, 2, 2],扩张率为 [1, 2],以捕捉动作数据在时间维度上的局部与全局特征。训练过程共进行 50 个 epoch,其中前 5 个 epoch 采用学习率预热(warm-up)策略,以平稳启动训练过程。优化器选用随机梯度下降(SGD),初始学习率设置为 0.025,权重衰减系数为 0.0005,动量参数为 0.9,以加速收敛并防止学习过程中的震荡。损失函数采用带标签平滑(label smoothing)的交叉熵损失,平滑系数为 0.1,同时引入温度参数 1.1,以增强模型对不确定性的鲁棒性。

表 3-5 训练参数设置

参数名称	参数值
训练样本数	44460
动作类别数	1380
批量大小	32
关节数	21
位姿数	120
随机丢弃率	0.2
注意力头维度	4
TCN 卷积核大小	3
TCN 步长	[1, 2, 2]
TCN 膨胀率	[1, 2]
训练轮数	50
预热轮数	5
优化器	随机梯度下降
学习率	0.025
权重衰减	0.0005
动量	0.9
损失函数	交叉熵损失
标签平滑	0.1
温度参数	1.1

训练过程中,使用 tensorboard 分别记录了训练中学习率、损失、准确率的变化情况。学习率变化曲线如图 3-12 所示,损失变化曲线如图 3-13 所示,准确率变化曲线如图 3-14 所示。

从图 3-12 中可以看出,学习率在训练初期经历了快速增长,并在大约第 10 个 epoch 后保持稳定。随后,在第 25 个 epoch 左右,学习率出现了阶梯式下降,这表明采用了分段常数衰减的学习率调度策略。这种策略在训练初期保

持较大学习率以加速收敛，在训练后期以较低的学习率细化模型参数。学习率发生突变时，损失和准确率也同样发生了较明显的变化，这说明了学习率调度策略有效性。




图 3-12 学习率变化曲线




图 3-13 损失变化曲线




图 3-14 准确率变化曲线

从图 3-13 可以观察到，训练过程中模型在训练集和验证集上的损失值持续降低，表明参数优化效果显著，训练过程是有效的。图 3-14 表示训练准确率和验证准确率均随着训练的进行呈现出上升趋势，这表明模型在训练集和验证集上的性能表现具有一致性，未显示出显著的过拟合迹象，反映出该模型具备一定泛化性。然而，在大约第 25 个 epoch 后，验证准确率的上升速度开始

减缓，这与验证损失的变化趋势相一致，暗示模型可能接近其性能瓶颈，还存在一定改进空间。在验证集和训练集上的损失与精度差异明显，表明二者存在一定的分布差异。

3.4.4 多模态动作识别网络实验评估

本小节旨在通过公开数据集 Assembly101 对多模态数据驱动的动作识别网络进行实验评估。该网络通过融合视觉外观信息和手部运动信息来提高动作识别的准确性。实验过程中使用到的数据同上一节一致。本研究采用标准化的预处理流程来规范数据输入并增强模型泛化能力。针对 RGB 数据，通过尺寸缩放、随机裁剪等操作进行数据增强，随后进行归一化处理；对于手部关节点数据，则采用随机裁剪和时序插值技术来保证数据格式一致性并实现时序增强。

表 3-6 训练参数设置

参数名称	参数值
训练样本数	44460
动作类别数	1380
批量大小	12
输入尺寸	224
帧数	8
关节数	21
位姿数	120
随机丢弃率	0.2
注意力头维度	4
TCN 卷积核大小	3
TCN 步长	[1, 2, 2]
TCN 膨胀率	[1, 2]
训练轮数	50
预热轮数	5
优化器	随机梯度下降
学习率	0.01
权重衰减	0.0005
动量	0.9
损失函数	交叉熵损失
标签平滑	0.1
温度参数	1.1
动作分类损失权重	1.0
特征损失权重	2.0

在本研究中，为了确保动作识别模型能够实现有效的训练与优化，对训练

参数进行了精心的设置，具体如表 3-6 所示，其中大部分的参数的设定与表 3-5 保持一致，以维持实验的连贯性。然而，为了更好地适应模型结构的变化，对批量大小和学习率进行了调整，将批量大小修改为 12，学习率调整为 0.01。此外，还引入了多种损失函数，为了平衡不同损失项的贡献，设置了动作损失、动词损失、名词损失和特征损失的权重，分别为 1.0、1.0、1.0 和 2.0，旨在通过多任务学习进一步提升动作识别的性能。

训练过程中，使用 **tensorboard** 分别记录了训练中学习率、损失、准确率的变化情况。学习率变化曲线如图 3-15 所示，损失变化曲线如图 3-16 所示，准确率变化曲线如图 3-17 所示。

图 3-15 展示了模型训练过程中学习率的变化情况。从图中可以看出，学习率的变化采取了学习率预热和分段常数衰减策略。学习率预热目的是在训练的初期阶段提高训练的稳定性，防止刚开始训练时使用过大的学习率导致模型参数的剧烈变化，进而影响模型的训练效果。分段常数衰减策略在训练初期保持较高的学习率加速收敛，训练后期以较低的学习率细化模型参数，避免过大的学习率导致模型在最优解附近震荡。




图 3-15 学习率变化曲线




图 3-16 损失变化曲线




图 3-17 准确率变化曲线

图 3-16 展示了模型在训练过程中损失函数的变化情况。从图中可以观察到，随着训练轮数的增加，损失函数值呈现出明显的下降趋势，表明模型在不断学习并逐渐优化。在训练初期，损失值下降较快，说明模型在初期学习到了较多的信息；随着训练的进行，损失值的下降速度逐渐放缓，直至趋于平稳，表明模型逐渐接近收敛状态。此外，损失曲线的平滑性表明训练过程较为稳定，没有出现明显的震荡或发散现象。

图 3-17 展示了模型训练过程中准确率的变化趋势。可以观察到，准确率在训练初期迅速上升，从初始的 0.2 左右快速增加至 0.4 左右，表明模型在训练初期能够快速学习并捕捉到数据的基本特征。随着训练的进行，准确率的提升速度逐渐放缓，但在第 25 个 epoch 之后出现了显著的增长，最终在第 50 个 epoch 时达到 0.42 左右。在训练的后期，准确率的提升趋于平缓，表明模型逐渐收敛。整体而言，模型训练过程表现出良好的学习能力和泛化能力，验证了所采用的训练策略和模型结构的有效性。




图 3-18 动作识别结果可视化

图 3-18 展示了动作识别模型的可视化预测结果，其中包括每个动作的预测标签、对应的概率值以及实际标签。预测的概率有利于判断动作识别的难易程度，可视化预测结果不仅验证了模型在动作识别任务中的有效性，而且为进一步分析模型性能和优化提供了重要依据。

本研究使用了类激活映射（Class Activation Mapping, CAM）技术对模型的关注区域进行可视化分析。通过生成 CAM 热力图，可以直观地展示模型在进行动作分类决策时重点关注的区域。如图 3-19 所示，通过对 CAM 热力图的可视化分析发现，本模型在动作识别过程中不仅关注与装配对象本身的状态变化，同时也关注着桌面上其他零部件的变化，这些都能够为动作识别提供有效的特征，在一定程度上增强了模型的可解释性。




图 3-19 动作识别 CAM 热力图

表 3-7 展示了本研究中训练的三个模型在验证集上的性能对比结果。实验结果表明，三种模型在验证集上的表现存在显著差异。其中，基于 RGB 特征的 TSM-ResNet50 模型在动词分类、名词分类和动作分类任务上的准确率分别为 64.86%、47.26%和 37.13%，均优于基于手部关节点特征的 MS-TCN 模型，说明 RGB 特征对于动作识别任务相对于手部关节点特征有更多的有效信息，纯手部关节点特征由于缺乏上下文信息导致精度较低。而融合模型（TSM-ResNet50+MS-TCN）在三项任务上均取得最佳性能，准确率分别达到 67.19%、52.47%和 42.37%，较单一模型提升显著，这表明 RGB 特征和手部关节点运动特征具有一定互补性，二者的有效结合能够进一步提升动作预测的准确性。这一结果验证了多模态特征融合策略在本研究任务中的有效性。

表 3-7 不同模型动作识别结果对比

模型	动词分类 准确率	名词分类 准确率	动作分类 准确率
TSM-ResNet50	64.86%	47.26%	38.13%
MS-TCN	63.84%	34.35%	27.64%
TSM-ResNet50+MS-TCN	67.19%	52.47%	42.37%

3.5 本章小结

本章针对多模态数据驱动的装配动作识别方法进行了全面的研究。首先，对动作识别任务展开简要介绍，并概述了相关数据集的特点。在此基础上，详细阐述了所使用的动作识别网络架构，包括数据前处理模块、RGB 特征提取模块、关节运动特征提取模块、多模态特征融合模块以及时序 Transformer 模块。随后，基于公开数据集，对模型进行了性能评估，实验结果表明，多模态动作识别网络在动词、名词和动作分类准确率上均优于单一模态的识别网络，动作分类准确率相对于基于 RGB 特征的 TSM-ResNet50 网络和基于手部关节运动特征的 MS-TCN 网络分别提高了 4.24%、14.73%。这表明多模态动作识别网络能够有效地融合视觉外观信息和手部运动信息，显著提高动作识别的准确性。

第4章 基于门控时序扩散网络的 装配动作预测方法研究

4.1 引言

动作预测作为智能制造领域的关键技术,对提升生产线自动化水平和作业效率具有重要意义。传统时序动作预测方法往往难以有效建模装配过程中复杂的时间依赖关系和动作间的逻辑约束,导致预测精度受限。针对这一问题,本章采用了一种基于门控时序扩散网络的装配动作预测方法。该方法创新性地将扩散模型的生成能力与时序门控机制相结合,通过构建多尺度时序特征提取网络,实现对装配动作序列的精准建模与预测。本章完成了整个动作网络的构建并且在公开数据集上进行了实验验证。

4.2 动作预测任务建模与数据预处理

4.2.1 动作预测任务建模

在动作预测任务中,短期预测和长期预测有着本质的区别。短期预测通常关注于未来几秒内的动作变化,例如预测一个正在进行的动作的结束时间或下一个即将发生的动作。这类预测任务相对简单,因为其时间范围较短,动作的不确定性和复杂性较低。然而,长期预测则需要考虑更长时间范围内的动作序列,甚至可能涉及数分钟的未来活动。这种预测任务更具挑战性,因为需要考虑动作之间的复杂依赖关系、上下文信息以及潜在的环境变化。

对于人机协作场景,长期动作预测显得尤为重要。例如,在工业环境中,协作机器人需要提前了解人类工人的动作计划,以便安全、高效地完成任务。如果机器人仅依赖于短期预测,它可能无法及时做出反应,从而导致效率低下甚至安全问题。相比之下,长期预测能够为机器人提供更全面的动作序列信息,使其能够提前规划路径、调整姿态,并在必要时进行干预。这种能力对于实现自然、高效的人机交互至关重要。

在进行网络选择与设计之前,首先对长期动作预测任务进行建模。给定一个总帧数为 N 的视频,其中 aN 帧作为观察部分,目标是预测未来 bN 帧的动作标签。其中, $N_o = aN$ 表示观察到的帧数, $N_a = bN$ 表示需要预测动作类别的帧数,而 $N = N_o + N_a$ 是考虑的总帧数, a 和 b 是两个正数且需要满足 $a + b < 1$ 。随机长期动作预测任务可以表述为从条件联合概率分布中抽取样本,以预测每帧未来动作,公式如下:

$$\hat{x}_{N_o+1:N} \sim p_{\theta}(x_{N_o+1}, \dots, x_N | F) \quad (4-1)$$

其中, $F = (\varphi(m_1), \dots, \varphi(m_{N_o})) \in R^{N_o \times D}$, m_k 表示第 k 帧的输入, φ 是特征提取网络, 本研究使用上一章中经过预训练的动作识别网络进行特征提取, x_i 是对应于第 i 帧的动作标签, 而 $x_{i:j}$ 表示从第 i 帧到第 j 帧的动作标签序列。长期动作预测的目标是从观察到的视频中预测在给定时间范围内接下来会发生什么, 即预测未来每一帧将要发生的动作标签。

4.2.2 数据预处理

数据预处理是动作预测任务中不可或缺的环节, 其目的在于将原始视频数据和标注信息转换为适合模型输入的格式, 同时消除数据中的不一致性, 提升模型的训练效率和预测性能。合理的预处理步骤能够显著增强模型对输入数据的适应性, 确保训练过程的稳定性和收敛速度。

首先, 从原始视频数据中进行特征提取是预处理的第一步。原始视频数据通常以像素级信息存储, 直接使用这些数据作为模型输入会导致计算成本过高, 且难以捕捉到与动作预测相关的高级语义信息。因此, 首先需要对原始视频数据进行特征提取, 以生成更具代表性和紧凑性的特征表示。本研究使用了上一章中经过预训练的动作识别网络实现特征提取, 为后续的预测任务提供了更丰富的上下文支持。

接着将类别标签转换为独热编码 (one-hot encoding) 形式。独热编码是一种常用的标签表示方法, 它将每个类别标签转换为一个长度为类别总数的二进制向量, 其中对应类别的位置为 1, 其余位置为 0。这种表示方式不仅便于模型计算类别概率分布, 还能有效处理多类别分类问题。在预处理阶段, 将原始类别标签转换为独热编码形式, 并存储为张量, 供模型训练使用, 标签使用独热编码形式有利于后续扩散模型的训练。

由于视频样本的长度存在差异, 直接输入模型会导致处理上的困难。为了便于批量处理, 需要对每个批次中的样本进行长度对齐。具体而言, 针对每个批次, 首先找出最长的样本序列长度, 以此为基准, 对其他较短的样本进行零填充 (Zero-Padding), 确保训练过程中所有样本的长度一致。同时, 为了保持标签信息与特征数据的对应关系, 也需要对标签进行相应的零填充处理。这种长度对齐方法不仅解决了样本长度不一致的问题, 还避免了因视频长度差异导致的计算问题, 确保了模型输入的一致性和稳定性。

在训练过程中, 为了模拟实际预测场景并提高模型对未来动作的预测能力, 需要对部分标注数据进行掩码处理。具体而言, 根据标签序列的长度创建掩码张量, 接着根据设定的观察与预测帧的占比, 用 0 和 1 填充掩码张量。通过掩

码遮盖，模型可以明确区分训练时使用的标签和需要预测的标签，从而避免信息泄露，确保预测任务的合理性。

整个数据预处理流程如图 4-1 所示。数据预处理通过特征提取、独热编码转换、长度对齐以及掩码创建等步骤，将原始数据转换为适合模型输入的格式。这一过程不仅提高了数据的可用性，还为模型的高效训练和准确预测提供了有力支持。




图 4-1 数据预处理流程图

4.3 基于门控时序扩散的动作预测网络结构

4.3.1 扩散模型

扩散模型（Diffusion Model）是一类基于概率生成模型的深度学习方法，其核心思想是通过逐步添加噪声将数据分布转化为简单分布（如高斯分布），再通过逆向过程从简单分布中恢复原始数据分布，如图 4-2 所示。这一过程可以类比于物理中的扩散现象，例如热量从高温区域向低温区域的扩散，而逆向过程则类似于从噪声中恢复原始数据。扩散模型在图像生成、时序数据建模等领域展现了强大的能力，其理论基础主要来源于非平衡态热力学和马尔可夫链。




图 4-2 扩散模型

扩散模型的生成机制包含两个关键阶段：前向扩散过程和逆向扩散过程。

前向扩散过程是一个马尔可夫链，其目标是将数据逐步加噪，最终将其转换为高斯噪声分布。假设 x_0 是原始数据，经过 t 步扩散后，数据变为 x_t ，其中 x_t 接近高斯噪声，每一步的扩散过程可以表示为：

$$x_t = \sqrt{(1 - \beta_t)}x_{t-1} + \sqrt{\beta_t}\varepsilon_t \quad (4-2)$$

其中， β_t 是第 t 步的噪声方差系数，通常是一个小的正数，且满足 $0 < \beta_t < 1$ ； ε_t 是标准高斯噪声， $\varepsilon_t \in N(0, I)$ 。随着 t 的增加，数据逐渐被噪声淹没，最终 x_t 接近纯噪声分布。令 $\alpha_t = \prod_{i=1}^t (1 - \beta_i)$ ，可以得到：

$$x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\varepsilon_t \quad (4-3)$$

前向扩散过程的联合分布可以表示为：

$$q(x_{1:T}|x_0) = \prod_{t=1}^T q(x_t|x_{t-1}) = \prod_{t=1}^T N(x_t; \sqrt{\alpha_t} x_0, (1 - \alpha_t)I) \quad (4-3)$$

逆向扩散过程的目标是从高斯噪声 x_t 中逐步恢复出原始数据 x_0 。这一过程同样是一个马尔可夫链，但与前向扩散过程相反，每一步的目标是减少噪声。逆向扩散过程的联合分布可以表示为：

$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=1}^T p_\theta(x_{t-1}|x_t) \quad (4-4)$$

其中， $p(x_T)$ 是标准高斯分布， $p_\theta(x_{t-1}|x_t)$ 是逆向扩散过程的条件概率分布，通常假设为高斯分布：

$$p_\theta(x_{t-1}|x_t) = N(x_{t-1}; \mu_\theta(x_t, t), \sum_\theta(x_t, t)) \quad (4-5)$$

扩散模型的训练目标是最小化前向分布 $q(x_{1:T}|x_0)$ 和逆向分布 $p_\theta(x_{0:T})$ 之间的 KL 散度。通过推导，可以得到以下简化目标函数：

$$L(\theta) = E_{t, \varepsilon_t} [||f_\theta(x_t, t) - x_0||^2] \quad (4-6)$$

其中， E 表示期望值，即对所有可能的 t 和 ε_t 求平均值， $f_\theta(x_t, t)$ 是一个去噪生成器网络， $f_\theta(x_t, t) = \hat{x}_{0,t}$ 该网络能够逆转噪声并预测 x_0 的重建 $\hat{x}_0$ ，上述目标函数表明最小化重建前后的误差。

训练完成后，从扩散模型中采样需要遵循一系列去噪步骤。在 DDPM 的采样过程中，推理需要 T 个去噪步骤。从时间步 $t = T$ 开始，从 $x_T \sim N(0, I)$ 中随机抽取样本，并将其输入生成器 f_θ 以预测 $\hat{x}_{0,T}$ 。假设已经在时间步 t 时采样了 x_t 并重建了 $\hat{x}_{0,t}$ ，则可以通过下面的步骤生成下一个样本 x_{t-1} 。

首先近似 ε_t ，公式如下：

$$\hat{\varepsilon}_t = \frac{1}{\sqrt{1 - \alpha_t}} (x_t - \sqrt{\alpha_t} \hat{x}_{0,t}) \quad (4-7)$$

由于在给定 x_0 的条件下，逆向转换概率 $q(x_{t-1}|x_t, x_0)$ 变为可处理的，并且可以表示为高斯分布 $N(x_{t-1}; \tilde{\mu}_t; \tilde{\beta}_t I)$ ，因此可以估计该高斯分布的参数：

$$\hat{\mu}_t = \sqrt{\alpha_{t-1}} \hat{x}_{0,t} + \sqrt{(1 - \alpha_{t-1} - \tilde{\beta}_t)} \hat{\varepsilon}_t, \tilde{\beta}_t = \frac{1 - \alpha_{t-1}}{1 - \alpha_t} \beta_t \quad (4-8)$$

接着从 $N(x_{t-1}; \tilde{\mu}_t; \tilde{\beta}_t I)$ 采样 x_{t-1} ，步骤持续进行，直到 $t = 1$ ，此时 $\hat{x}_{0,1}$ 被视

为最终生成的样本。对于 DDIM 采样方案，在推理过程中将转换概率的方差设置为 0，即 $\tilde{\beta}_t = 0$ ，使得去噪过程中对于特定的样本 x_t 变为确定性的，即 $x_{t-1} = \hat{\mu}_t$ 。这可以使得采样过程在更少的步骤内完成，加速了扩散模型的推理过程。

4.3.2 门控时序预测网络

从上一小节的内容中可知生成器网络 f_θ 的设计是扩散模型的核心组件之一。为了有效地捕获输入数据中的时序特征，本研究采用了时序卷积层来构建生成器网络。由于输入序列由观测帧和未来帧这两部分截然不同的数据组成，直接应用传统的时间卷积层并不适宜。这是因为传统方法无法有效地区分观测和未来帧，导致所有数据被同等对待，从而无法充分利用输入数据的特性。为了解决这一问题，本研究采用了门控时序卷积，使生成器网络能够自适应地控制过去和未来帧之间的信息混合程度。

本研究使用了一种门控时序预测网络作为生成器，该网络由 S 个阶段组成，每个阶段都能产生一个包含动作概率的输出向量，覆盖所有动作类别。每个阶段包含 L 个带有门控机制的膨胀卷积残差层，如图 4-3 所示。每个卷积残差模块由两个扩张时间卷积层构成：一个用于特征处理，称为特征卷积，另一个用于对特征进行门控，称为门控卷积。




图 4-3 门控时序预测网络

该网络的输入包括经过零填充的当前帧和未来帧的联合表示序列，以及初始高斯噪声。带有门控机制的膨胀卷积残差层能使某些帧的特征失效。带有门控机制的膨胀卷积残差层是整个网络的基本构建单元，每个块内部包含以下关键组件：

- (1) 特征卷积：对输入特征进行卷积操作，提取时间序列中的关键特征。
- (2) 门控卷积：与特征卷积并行，用于控制特征的激活，即决定在特定

时间步长哪些特征应该被强调或抑制。

(3) 逐元素乘积：将特征卷积的输出与门控卷积经过 Sigmoid 激活后的输出进行逐元素乘积，从而实现对特征的动态选择。

(4) 1×1 卷积层：用于调整特征图的通道数，通常用于整合特征。

(5) ReLU 激活函数：在 1×1 卷积层之后应用，引入非线性，使网络能够学习更复杂的特征表示。

(6) 残差连接：通过残差连接将输入直接添加到输出，有助于缓解深层网络训练中的梯度消失问题。

其中，门控卷积的作用是通过门控机制自适应地决定在网络的不同层级中过去和未来之间的信息混合程度。这种机制允许模型在不同时间步长动态调整对过去和未来帧的关注程度，从而更有效地处理时间序列数据，以便更好地完成动作预测任务。

具体来说，对于输入特征向量 $\tilde{H}_{s,l-1}$ ，第 s 阶段第 l 层的门控卷积输出 $\bar{H}_{s,l}$ 的计算公式如下：

$$\bar{H}_{s,l} = \sigma(W_g * \tilde{H}_{s,l-1} + b_g) \otimes (W_f * \tilde{H}_{s,l-1} + b_f) \quad (4-9)$$

其中 σ 表示 Sigmoid 激活函数， $*$ 表示卷积操作， $\otimes$ 表示逐元素乘积。 W_g 和 W_f 分别是门控卷积和特征卷积的滤波器权重， b_g 和 b_f 是相应的偏置项。输出的 $\bar{H}_{s,l}$ 随后通过一个 Dropout 层，再经过一个 1×1 卷积层和 ReLU 非线性激活函数处理。最后，通过在 ReLU 激活后应用残差连接来计算该层的输出。在每层 l 中，门控卷积和特征卷积的膨胀因子设置为 2^l ，即随着层数的增加，膨胀因子以 2 的倍数递增。

整个门控时序预测网络由多个阶段组成，每个阶段的输出都会计算损失，以指导模型训练。损失函数用于评估模型预测的去噪动作标签与真实标签之间的差异。该网络的优化目标函数通过量化预测去噪动作标记与真实标记之间的偏差程度来指导参数更新。通过最小化损失函数，模型能够逐步提高其预测的准确性。最终，模型输出的预测结果 $\hat{Y}$ 是对预测帧和未来帧的联合预测，这一结果综合了所有阶段的信息。

4.3.3 门控时序扩散网络

扩散模型在高维输出空间中表现出良好的扩展性，这对于联合推断一系列未来动作特别有用，因为它鼓励时间上的动作一致性并避免过于短视的规划。扩散模型的稳定训练特性也使其在处理复杂动作预测任务时更加可靠。然而，当将其直接应用于动作预测任务时，会遇到一些问题。首先，标准的扩散模型主要设计用于图像、音频等连续数据的生成，而动作预测涉及到的是离散的动

作标签，这就需要对模型进行适当的调整。其次，扩散模型通常不包含条件信息，即它在生成过程中不会利用额外的上下文信息，这对于动作预测来说是一个限制，因为动作预测往往需要依赖于视频的上下文信息。针对这些问题，本研究进行了一些关键变化以使扩散模型适用于动作预测。

为了使用连续状态扩散模型对离散动作类别进行建模，本研究将动作标签表示为独热编码向量 $\mathbf{x}_0 \in R^{N \times C}$ ，可以将这些标签视为可以在连续状态空间中直接进行建模的连续变量。如此一来，训练过程保持不变，推理过程也保持不变，只是在将生成的样本映射回离散域时，在类别维度上选择最大值即可完成映射。

为了根据观察到的帧对生成过程进行条件化，本研究采用了逐帧特征向量 F ，并将其扩展为观察到的动作变量和未来动作变量的逐帧条件。具体来说就是通过引入零填充来补偿未来未观察到帧的缺失特征。假设观察到的帧特征为 $\varphi(m_1), \dots, \varphi(m_{N_0})$ ，其中 N_0 表示观察到的帧数。对于未来未观察到的帧，我们用零向量进行填充，以表示这些帧的缺失信息。因此，扩展后的特征向量 $\tilde{F}$ 可以表示为：

$$\tilde{F} = (\varphi(m_1), \dots, \varphi(m_{N_0}), 0, \dots, 0) \in R^{N \times D} \quad (4-10)$$

其中， N 是总帧数，包括观察到的和未来未观察到的帧， D 是特征维度。通过这种方式， $\tilde{F}$ 可以作为逐帧扩散生成过程的条件输入。

在扩散模型的每个时间步 t 中，将填充后的观察帧特征 $\tilde{F} \in R^{N \times D}$ 与当前样本 $\mathbf{x}_t \in R^{N \times C}$ 进行通道级拼接。这种拼接操作使得生成器 f_θ 能够同时接收观察到的帧特征和当前噪声样本的信息，从而更好地建模观察到的动作和未来动作之间的关系。

此外，本研究还使用了自条件化机制。具体来说，就是将上一次估计的输出 $\hat{\mathbf{x}}_{0,t+1} \in R^{N \times C}$ 作为生成器 f_θ 的附加输入。这种自条件化机制允许生成器在每一步中利用之前步骤的预测结果，从而提高生成的准确性和连贯性。生成器的输入可以表示为：

$$f_\theta(\mathbf{x}_t, \hat{\mathbf{x}}_{0,t+1}, \tilde{F}, t) = \hat{\mathbf{x}}_{0,t} \in R^{N \times C} \quad (4-11)$$

在训练过程中，为了增强模型的鲁棒性，以概率 p 随机将 $\hat{\mathbf{x}}_{0,t+1}$ 设置为零。这种操作相当于在某些情况下不使用自条件化来训练 f_θ ，从而让模型学会在有若无自条件化的情况下都能生成合理的输出。

最后，为了将时间步 t 的信息融入生成器的输入中，将时间步 t 编码为正弦位置嵌入。这种位置嵌入技术能够将时间步的信息有效地融入特征中，使得生成器能够更好地捕捉时间序列中的动态变化。

上述改进可以总结为离散化处理标签、特征拼接、在生成器中引入自条件化。通过这些改进，可以将观察到的帧特征和未来动作的不确定性结合到扩散模型中，扩散模型就能更好地适应动作预测任务，生成更加准确和连贯的未来动作序列。整个门控时序扩散网络的工作流程如图 4-4 所示。




图 4-4 门控时序扩散网络工作流程

模型首先接收高斯噪声 x_T 和零填充后的特征 $\tilde{F}$ 作为输入。然后，门控时序预测网络根据这些输入预测去噪后的动作标签 $\hat{x}_{0,T}$ 。在随后的时间步中，模型使用自条件机制，将前一时间步的预测结果作为额外输入，以提高预测的准确性。通过这种方式，模型能够逐步从噪声中恢复出准确的动作标签，从而实现动作预测。

4.3.4 学习目标

在训练阶段，为了使模型能够学习从噪声中恢复出真实的动作序列，采用了扩散模型的训练策略。具体而言，从均匀分布 $U(1, T)$ 中随机采样一个时间步 t ，并根据给定的观察特征 $\tilde{F}$ 和真实值 x_0 计算得到 x_t 。然后应用门控时序预测网络作为生成器 $f_\theta(x_t, \hat{x}_{s,0,t+1}, \tilde{F}, t)$ ，生成一系列逐阶段的预测结果 $\{\hat{x}_{s,0,t}\}_{s=1}^S$ 。如果 $t < T$ ，则包含步骤 $t+1$ 的预测 $\hat{x}_{s,0,t+1}$ 作为自条件输入。

本研究所使用的模型通过逐阶段的预测来逐步恢复出完整的动作序列。具体来说，模型包含了 S 个阶段，每个阶段都会生成一个预测结果，本研究使用了所有 S 个阶段的均方误差作为损失函数进行训练，具体公式如下：

$$L = E_{t, \epsilon_t} \left[\sum_{s=1}^S \|\hat{x}_{s,0,t} - x_0\|^2 \right] \quad (4-12)$$

其中， E 表示期望值，即对所有可能的 t 和 ϵ_t 求平均值。这个损失函数的设计旨在最小化模型预测与真实数据之间的差异，从而确保模型能够准确地从噪声中恢复出真实的动作序列。

在推理阶段，本研究采用 DDIM 的采样方案，并使用了 D 个去噪步骤来

生成最终的预测结果，取门控时序预测网络最后一个阶段在去噪步骤 $t = 1$ 时的重建结果作为模型的最终输出，即 $\hat{x} = \hat{x}_{S,0,1}$ 。

4.4 基于公开数据集的装配动作预测实验与结果分析

4.4.1 评价指标

在动作预测任务中，为了全面评估模型的性能，通常采用两种主要的评价指标：帧平均准确率（Mean of Frames Accuracy, MoF）和类别平均准确率（Mean of Classes Accuracy, MoC）。这两种指标分别从帧级别和类别级别的角度对模型的预测结果进行量化评估，能够反映模型在不同粒度上的表现。

帧平均准确率（MoF）是衡量模型在所有帧上的整体预测准确率的指标。MoF 反映了模型在整个视频序列中的全局预测性能。由于 MoF 是基于帧的统计，它对类别不平衡问题不敏感，能够直观地反映模型在所有帧上的整体表现。其计算公式如下：

$$\text{MoF} = \frac{\sum_{i=1}^N I(x_i = \hat{x}_i)}{N} \times 100\% \quad (4-13)$$

其中， N 表示总帧数， x_i 表示第 i 帧的真实标签， $\hat{x}_i$ 表示第 i 帧的预测标签， $I(\cdot)$ 表示指示函数，当 $x_i = \hat{x}_i$ 时为 1，否则为 0。

类别平均准确率（MoC）是衡量模型在每个类别上的平均预测准确率的指标。MoC 反映了模型在每个类别上的预测性能，并对所有类别的准确率取平均。由于 MoC 是基于类别的统计，它对类别不平衡问题更为敏感，能够更好地反映模型在少数类别上的表现。其计算公式如下：

$$\text{MoC} = \frac{1}{N_c} \sum_{j=1}^{N_c} \frac{\sum_{i=1}^N I(x_i = j \wedge \hat{x}_i = j)}{\sum_{i=1}^N I(x_i = j)} \times 100\% \quad (4-14)$$

其中， N_c 表示类别总数， j 为类别索引， $j \in \{1, 2, \dots, N_c\}$ ， N 表示总帧数， x_i 表示第 i 帧的真实标签， $\hat{x}_i$ 表示第 i 帧的预测标签， $I(\cdot)$ 表示指示函数，当条件成立时为 1，否则为 0。

MoF 和 MoC 分别从帧级别和类别级别对模型的预测性能进行评估，二者相辅相成，能够全面反映模型的表现。具体而言，MoF 关注的是模型在所有帧上的整体准确率，适合评估模型在全局上的表现；而 MoC 关注的是模型在每个类别上的平均准确率，适合评估模型在类别平衡性和少数类别上的表现。在实际应用中，通常需要结合 MoF 和 MoC 来综合评估模型的性能。例如，

针对类别分布失衡的数据集，模型可能在样本量充足的类别上表现良好，从而获得较高的 MoF，但在样本稀缺的类别上表现较差。此时，MoC 能够更敏感地反映出模型在少数类别上的不足。因此，MoF 和 MoC 的结合使用能够为模型性能评估提供更全面的视角。

4.4.2 参数设计

在动作预测网络的实验中，本研究综合考虑了模型结构、训练过程和优化策略等多方面的参数配置，以确保模型在实验阶段能够高效学习并具备良好的泛化能力。针对模型结构参数，本研究设计了包含多个阶段和层次的网络架构。使用结合 RGB 和手部关节点特征提取网络，提取到的特征维度为 2048，能充分捕捉动作数据的细节特征；同时，基于门控时序扩散的动作预测网络的层数和阶段数分别设置为 9 层和 5 阶段，以实现动作序列的多层次建模和特征融合。训练参数中 batch size 设置为 16，以平衡计算资源和内存占用；采样率设置为 6，即每间隔 6 帧提取 1 帧的特征，确保动作序列不会过于长从而降低模型训练的效率；训练轮数设置为 100 轮，以保证模型充分学习数据特征。扩散模型中的时间步长设置为 1000 步，以支持对动作动态变化的精细建模。优化策略方面，采用 Adam 优化器，学习率设置为 0.0005，并结合 0.3 的 Dropout 比率，以实现快速收敛的同时防止过拟合。损失函数采用均方误差损失，通过量化预测去噪动作标记与真实标记之间的偏差程度来指导模型参数更新。

表 4-1 训练参数设置

参数	设置
批量大小	16
特征维度	2048
降采样率	6
训练轮数	50
预热轮数	5
扩散步数	1000
阶段数	5
层数	9
优化器	Adam
学习率	0.005
随机丢弃率	0.3
损失函数	均方误差

具体的参数设置如表 4-1 所示。本研究通过合理配置模型结构参数、训练参数和优化策略，确保了动作预测网络在实验中的高效训练和稳定性能。这些参数设置为后续实验的顺利开展提供了坚实的基础，并为动作预测网络的进一步优化提供了参考依据。

4.4.3 实验结果与分析

基于上一节设置的实验参数，本研究在公开数据集 Assembly101 上对提出的装配动作预测模型进行了系统训练与评估。训练过程中，采用 Tensorboard 工具对关键训练指标进行实时监测与记录，包括学习率变化、损失函数值、帧平均准确率（MoF）以及类别平均准确率（MoC）等指标。




图 4-5 学习率变化曲线

图 4-5 展示了训练过程中的学习率变化曲线。实验采用基础学习率为 0.005 的设置，该参数经过多次预实验验证确定。训练过程中实施了学习率预热（warm-up）与阶段性衰减策略：在前 5 个 epoch 采用线性 warm-up 策略使学习率从 0 逐渐增至 0.005；后续在第 30、40 个 epoch 时衰减为原来的 0.5 倍。这种策略的优势在于：1) warm-up 阶段有助于模型参数稳定初始化；2) 阶段性衰减策略能够在训练后期实现更精细的参数调整。




图 4-6 训练集损失变化曲线

训练过程中采用均方误差（MSE）作为损失函数，图 4-6 展示了训练集上的损失变化曲线。可以观察到，损失值在前 10 个 epoch 呈现快速下降趋势，说明模型参数得到有效更新；10-40 个 epoch 期间损失值下降趋缓，表明模型进入稳定优化阶段；40 个 epoch 后损失值基本收敛，波动幅度小于 0.01，证明训练过程达到稳定状态。





图 4-7 训练集 MoF 变化曲线

如图 4-7 所示，三条曲线分别表示了已观测到的帧的标签预测的 MoF、未观察到的帧的标签预测的 MoF，以及所有帧的 MoF。从图中可以看出，三者均呈现稳步上升趋势，并且逐渐趋于平缓。这一结果表明，模型在训练过程中能够有效地学习到动作特征，并且随着训练的进行，模型的性能逐渐提高并趋于稳定。



(a)观测比例为 0.2

(b)观测比例为 0.3

图 4-8 测试集训练损失变化曲线

图 4-8 中的图（a）和图（b）分别展示了在不同观测比例（0.2 和 0.3）下测试集上的损失变化情况。可以观察到，在两种观测比例下，测试损失均呈现出随训练轮次增加而下降的趋势，这表明模型在不断学习并逐渐适应测试数据。在初始阶段，损失值下降较快，随后逐渐趋于平缓，显示出模型收敛的迹象，这与训练集损失曲线下下降趋势一致，但是由于测试集和训练集还是存在一定的

分布差异，所以数值区间不太一致。




图 4-9 测试集 MoC/MoF 变化曲线

图 4-9 展示了在不同观测比例（0.2 和 0.3）下，模型在测试集上的 MoC 和 MoF 指标的变化趋势。具体而言，图 4-9(a)和图 4-9(c)分别显示了在观测比例为 0.2 和 0.3 时 MoC 指标的变化情况，而图 4-9(b)和图 4-9(d)则展示了相同观测比例下 MoF 指标的变化。可以观察到，在所有情况下，随着训练轮次的增加，MoC 和 MoF 指标均呈现出明显的上升趋势，表明模型对于动作上下文和特征的理解能力在不断提高。对于不同的预测比例，随着预测比例的提高，预测的性能也逐渐下降，这在四张图中表现一致，且结果符合理论。总体而言，这些结果表明所提出的模型能够有效地从观测数据中学习并预测动作特征和上下文，而预测比例的提升则会增加预测难度。

表 4-2 展示了不同方法在数据集 Assembly101 的长期动作预测任务中的性能对比，具体通过 MoC 和 MoF 两个指标在不同观测比例和预测比例的情况下进行评估。Tri-gram 和 UAAA 方法在相同条件下的性能则相对较弱，本文方法的提升幅度更为显著，显示出更强的鲁棒性和适应性。结果表明，本研究所提方法在长时序动作预测任务的精度方面优于其他方法。

表 4-2 不同方法指标对比

方法	观测比例	0.2				0.3			
		0.1	0.2	0.3	0.5	0.1	0.2	0.3	0.5
Tri-gram	MoC	7.2	6.7	6.1	5.4	6.1	5.8	5.4	5.2
	MoF	12.3	11.8	11.5	10.9	11.0	10.6	10.1	9.8
UAAA*	MoC	6.9	5.9	5.6	5.1	5.9	5.5	5.2	4.9
	MoF	11.3	10.1	9.5	9.1	10.1	9.8	9.6	9.0
本文方法	MoC	11.2	8.2	6.3	4.9	11.3	7.5	6.3	4.6
	MoF	18.6	15.4	14.5	12.9	15.1	13.8	12.8	12.0

4.5 本章小结

本章针对装配场景中的长时序动作预测问题,提出了一种基于门控时序扩散网络的创新解决方案。通过将扩散模型的优势与门控时序网络的动态特征提取能力相结合,实现了对装配动作序列的建模与预测。在方法实现层面,首先建立了装配动作预测的数学模型,设计了规范化的数据预处理流程;然后构建了用于动作预测的门控时序扩散网络结构,利用门控机制捕捉时序依赖关系,通过扩散过程预测未来的动作标签;最后在公开数据集上进行了实验验证。实验结果表明,所提方法在长时序动作预测任务的精度方面优于其他方法。

第 5 章 装配动作识别与预测实验

5.1 引言

本章围绕面向人机协作的装配动作识别与预测这一关键技术问题,通过系统性实验验证所提方法的有效性与实用性。首先,本章详细介绍了实验环境的搭建过程,包括硬件平台的布置与软件系统的开发;其次,阐述了针对装配任务特点设计的数据采集方案与标注;最后,通过实验与定量分析,验证了动作识别与预测模型的性能表现。

5.2 实验环境搭建

5.2.1 硬件平台搭建

传统工业装配场景中的人机协作主要为流水线式的空间共享模式,机器人与操作人员在固定工位上交替作业,形成时空分离的工作方式。这种模式下的人机交互程度有限,难以满足现代制造业对柔性化生产的要求。本研究聚焦于时空共享条件下的人机协同装配作业模式。如图 5-1 所示,该协作系统包括装配工作台、协作机器人、操作员、工具和零部件以及环境感知设备等要素,这种配置构建了一个典型的人机协同作业场景。环境被划分为操作人员独立工作区、机器人独立工作区和人机协作区。在操作人员独立工作区,人类可以利用工具进行工件装配;而在机器人独立工作区,机器人负责搬运或分拣工具和零部件;协作交互区则实现人机之间的工件传递与协同装配。这种空间划分方式通过物理隔离明确区分了人机各自的作业范围,在确保安全性的前提下,充分发挥了操作人员的灵活判断能力和机器人系统的精准执行特性。




图 5-1 人机协作装配工位布局图

本研究搭建的人机协作装配实验平台如图 5-2 所示，该环境由协作机器人、装配操作人员、装配工作区域、零件及工具存储区、实时数据处理终端和深度摄像设备等关键组成部分构成。在该协作环境中，操作员和机器人将处于同一时空进行装配作业，其中操作人员主要负责在装配工作区执行装配操作，深度相机可以实时采集人类装配过程中的 RGB 图像和深度图像并将其传输至数据处理设备中，接着利用已经训练好的模型进行人类装配动作识别与预测，预测结果将指示整个装配任务的进程，根据结果发送指令驱动机器人从零部件和工具存放区抓取后续工序所需的零部件或工具放至装配工作区，以辅助操作人员完成后续的装配步骤。



图 5-2 人机协作装配实验平台

5.2.2 软件系统构建

本节将详细介绍如图 5-3 所示的软件系统构建过程，该系统旨在实现人机协作工程中的人类动作识别与预测。系统采用模块化设计理念，由三个核心功能单元构成：1) 基于深度视觉的动作感知模块，负责实时采集操作者的运动数据；2) 多模态特征融合的动作识别模块，实现装配动作的精准分类；3) 基于门控时序扩散网络的预测模块，完成未来动作序列的推理。各模块通过标准化的数据接口实现高效协同，形成端到端的处理流程。其中，感知模块的输出作为识别模块的输入，识别结果又为预测模块提供关键先验信息，这种紧密耦合的架构设计确保了系统整体的实时性和可靠性。




图 5-3 软件系统框图

（1）基于深度相机的动作感知模块

该模块是系统的数据采集基础，负责从视觉感知设备获取 RGB 图像和手部关节点的三维坐标信息。系统首先通过视觉感知设备的深度传感器和 RGB 传感器分别捕获深度图像和 RGB 图像。随后，利用 Mediapipe 框架从 RGB 图像中提取手部关节点信息，并使用相机自带的人体跟踪模块对深度信息进行解析。通过深度信息对手部关节点的三维坐标进行优化，最终得到精确的手部关节点信息。这些手部关节点坐标及 RGB 图像将作为后续模块的数据输入，为动作识别提供基础数据。

（2）多模态数据驱动的动作识别模块

本模块是软件系统的核心之一，它利用手部关节点序列和 RGB 图像作为输入，通过人体动作识别模型进行动作分类。该模型结合了 RGB 特征和关节点特征，通过模态融合技术提高动作识别的准确性。识别结果包括动作分类和概率分布，为接下来的动作预测提供了已观测到的信息。这一模块的设计确保了系统能够从多模态数据中提取丰富的特征信息，从而提高动作识别的准确性和鲁棒性。

（3）基于门控时序扩散结构的装配动作预测模块

该模块负责基于已经观测到的人类动作信息预测接下来可能发生的动作，从而感知整个装配任务的任务进程。首先，该模块输入已观察到的动作特征及标签，根据预测比例构建预测标签张量并填充噪声。接着，将特征以及需要预测的标签输入带有自条件化机制和引入特征拼接的门控时序预测网络。经过若干个时间步的去噪过程，得到最终的预测结果，预测结果是逐帧标记的动作类别。根据预测结果可以感知整个装配任务的进程，从而指示机器人接下来需要完成的动作。

本研究中的整个软件系统在 Ubuntu20.04 操作系统中完成，使用 Python 语言实现。在数据采集与预处理过程中，使用 Azure Kinect SDK 完成了数据采集工作和人体跟踪工作，使用 Mediapipe 开源框架完成了手部关节点识别，利用 NumPy、Pandas 等库对采集到的原始数据进行初步数据预处理工作，并使用 OpenCV、Matplotlib 等库对实验数据进行可视化展示以便于直观分析。在模型训练与验证过程中，使用了 PyTorch 作为主要的深度学习框架，使用框架自带的训练工具，如 DataLoader、Optimizer 等完成了模型的训练和测试。同时，借助 TensorBoard 对训练过程进行可视化监控，实时观察模型的损失函数、准确率等指标的变化情况。采用 Scikit-learn 库中的评估指标对模型的性能进行评估。同时，使用混淆矩阵可视化工具直观展示模型的分类效果，以便对模型进行进一步优化。在整个软件系统的构建过程中，本研究采用了模块化设计方法，确保了系统的灵活性和可扩展性，同时保证数据流的顺畅和处理的高效。

5.3 装配实验设计与数据采集

5.3.1 多对象多序列装配任务设计

本研究的核心目的之一是使机器人能够适应人类操作员在面对不同装配对象以及不同装配顺序时的多样化行为模式。具体而言，机器人需要具备对人类操作员当前动作的识别能力，并能够基于此预测接下来可能发生的动作，从而准确判断是否需要提供协助。在这个过程中，机器人需要能够应对以下两种复杂性：

（1）不同装配对象的多样性：在实际工业场景中，人类操作员可能需要处理多种装配对象，每种对象的零部件结构、装配顺序各不相同。机器人需具备识别不同装配对象的能力，并根据具体任务调整其行为策略。

（2）装配顺序的灵活性：即使针对同一装配对象，人类操作员在实际操作过程中也可能采取不同的装配顺序。这种顺序的变动可能源于操作习惯、任

务优先级调整或外部环境变化等因素。机器人需要能够识别当前操作的动作序列，并预测下一步可能发生的动作，从而判断是否需要主动提供协助（如传递工具、固定零部件或纠正错误操作）。

为实现上述目标，本研究设计了多样化的装配任务实验场景。具体而言，实验设置了多种不同的装配对象，每种对象均具有独特的结构特点和装配要求。同时，针对同一装配对象，实验允许装配顺序的灵活变动，以模拟实际装配过程中可能出现的多种操作路径。通过这种实验设计，本研究能够更真实地反映人机协作中装配任务的复杂性和动态性。

为简化实验任务并确保研究的可操作性与可重复性，本研究选择以工程车玩具的装配任务作为实验对象。实验任务涉及两种典型的工程车模型：挖掘机和推土机，两种车的整车造型如图 5-4 所示。



(a)推土机



(b)挖掘机

图 5-4 拆装工程车玩具整体造型

每种车型均由多种零部件组成，这些零部件在形状、尺寸、功能以及相互配合关系上各不相同，进一步增加了装配任务的复杂性和多样性。两种车的拆解图如图 5-5 所示。从图中可以看出，两种车型在零部件组成上既存在显著差异，也具有一定的相似性。推土机主要由底座、车身、驾驶舱、推土铲、轮子等零部件组成。挖掘机主要由底座、前车身、后车身、驾驶舱、挖掘机臂、履带等零部件组成。这种设计使得实验任务既能够覆盖特定装配操作，又包含通用装配步骤，从而提供了多样化的装配场景，以验证在不同任务中的适应能力。



(a)推土机



(b)挖掘机

图 5-5 拆装工程车玩具拆解图

推土机包含的具体装配动作如表 5-1 所示，表中详细列出了推土机装配过

程中涉及的各个动作及其编号。装配顺序的约束条件如下：（1）安装车身（A2）需要在安装底座（A1）之后；（2）安装驾驶舱（A3）需要在安装车身（A2）之后；（3）安装臂连接器（A5）需要在安装车身（A2）之后；（4）安装推土机臂（A6）需要在安装臂连接器（A5）之后；（5）安装推土铲（A7）需要在安装推土机臂（A6）之后。除了上述顺序约束外，其他动作的顺序可根据操作者的习惯灵活调整。

表 5-1 推土机装配动作

动作编号	动作名称
A1	安装底座(install the base)
A2	安装车身(install the vehicle body)
A3	安装驾驶舱(install the cabin)
A4	安装车轮(install the wheels)
A5	安装臂连接器(install arm connector)
A6	安装推土机臂(install bulldozer arm)
A7	安装推土铲(install bulldozer shovel)

挖掘机包含的具体装配动作如表 5-2 所示，表中详细列出了推土机装配过程中涉及的各个动作及其编号。装配顺序的约束条件如下：（1）安装驾驶舱（A3）需要在安装前车身（A8）之后；（2）安装挖掘机臂（A12）需要在组装挖掘机臂（A11）之后。与推土机类似，除了上述顺序约束外，其他动作的顺序可根据操作者的习惯灵活调整。这种设计不仅体现了装配任务的逻辑性，还充分考虑了实际操作中的灵活性。

表 5-2 挖掘机装配动作

动作编号	动作名称
A8	安装前车身(install the rear body)
A9	安装后车身(install the front body)
A3	安装驾驶舱(install the cabin)
A10	安装履带(install the tracks)
A11	组装挖掘机臂(assemble excavator arm)
A12	安装挖掘机臂(install excavator arm)

5.3.2 装配动作数据采集与标注

本研究采用深度相机 Azure Kinect 作为装配动作数据采集设备，并使用桌面三脚架固定设备，其空间配置参数为：镜头光轴与工作台面呈 20° 俯角，设备安装位置位于操作者正前方 40 厘米处，镜头中心高度与工作台面保持 20 厘米垂直距离。该架设位置能够完整覆盖受试者的操作区域，确保装配动作的清

晰捕捉。数据采集过程中,实验人员坐于 Azure Kinect 相机的拍摄范围内,以保证数据的完整性和一致性。所有动作数据集均在相同的桌面装配场景中采集,未引入特殊的环境干扰因素,但由于数据采集的时间点不同,光照条件可能存在一定差异。

本研究共邀请了 5 名实验人员参与数据采集。每名实验人员需分别完成推土机和挖掘机两种车型的完整装配任务。在数据采集正式开始前,实验人员被允许对零部件进行简单熟悉,以减少因不熟悉操作而导致的无效数据的产生。同时为了保证实验数据的多样性,实验过程中允许实验人员在确保装配准确性的前提下可根据个人操作习惯灵活确定工序执行顺序。通过上述设置,本研究共采集了 100 条装配视频,其中推土机和挖掘机各 50 条。采集过程中,同时录制了 RGB 视频和深度视频,帧率均为 30fps,其中 RGB 视频的每帧分辨率为 1280×720 ,深度视频使用宽视场模式(WFOV),每帧分辨率为 512×512 。

数据采集完成后,需对采集到的视频数据进行时序动作标注。本研究使用开源工具 Vidat 进行标注,如图 5-6 所示,标注界面提供了直观的时间轴和视频帧浏览功能,便于精确标注动作的起止时间。标注过程中,需根据每个装配动作的起始时间和结束时间对视频进行切分,并为切分后的片段赋予对应的动作标签。切分时需要保证每个动作的结束帧为下一个动作的开始帧,以保证动作序列的连贯性。基于前期定义的 12 种装配动作类别,完成了全部视频数据的标注工作。




图 5-6 时序动作标注界面

标注完成后,对所有动作类别的总标注时长进行了统计,具体数据如表 5-3 所示。由于模拟装配过程是一个完整连续的过程,不同动作的持续时间不同,

所以不同的动作总标注时长存在一定差异。

表 5-3 装配动作类别总标注时长统计表

动作编号	动作名称	总标注时长
A1	安装底座(install the base)	24933 帧(831.77 秒)
A2	安装车身(install the vehicle body)	31992 帧(1067.07 秒)
A3	安装驾驶舱(install the cabin)	45925 帧(1532.14 秒)
A4	安装车轮(install the wheels)	61365 帧(2046.07 秒)
A5	安装臂连接器(install arm connector)	50720 帧(1691.37 秒)
A6	安装推土机臂(install bulldozer arm)	57266 帧(1909.47 秒)
A7	安装推土铲(install bulldozer shovel)	30992 帧(1033.67 秒)
A8	安装前车身(install the rear body)	33279 帧(1110.27 秒)
A9	安装后车身(install the front body)	17604 帧(587.47 秒)
A10	安装履带(install the tracks)	49934 帧(1664.91 秒)
A11	组装挖掘机臂(assemble excavator arm)	22840 帧(761.97 秒)
A12	安装挖掘机臂(install excavator arm)	15277 帧(509.84 秒)

本研究采用随机分层抽样的方法将数据集划分为训练集和验证集，其中 80%作为训练集，20%作为验证集。在划分过程中，充分考虑各类别样本的均衡性，确保每个动作类别在训练集和验证集中均保持近似比例，并且也考虑到了不同的实验人员的操作差异，每个实验人员的样本也会尽量均匀地出现在训练集和验证集中。同时采用随机分配策略，避免因数据排序等因素导致的分布偏差，从而保证模型训练和评估的有效性。




图 5-7 动作分类样本数统计

针对动作分类标注的准备工作，为模拟人机协作环境下实时动作检测的实际应用场景，对原始视频中的连续装配动作进行样本切分处理。具体而言，采用滑动窗口方法对视频序列进行分割，设置窗口大小为 80 帧（约 2-3 秒），

该时长基本能够覆盖单个动作的特征信息；滑动步长设为 40 帧，确保相邻窗口间具有 50%的重叠率，以增加样本多样性。当滑动窗口内的视频片段包含多个动作类别时，采用时间占比优先原则进行标注，即将该样本归类为窗口内持续时间最长的动作类别。这种处理方式既保持了动作样本的完整性，又有效增强了模型对动作边界的识别能力，为动作分类任务提供了高质量的训练数据。完成划分后总共获得了 9740 个动作片段，其中 7906 个样本为训练集，1834 个样本为验证集，具体的数据分布如图 5-7 所示。

5.4 动作识别与预测实验与结果分析

5.4.1 动作识别实验与结果分析

本研究使用了一种多模态动作识别网络实现装配动作识别，基于表 5-4 所示的参数设置开展动作识别实验。

表 5-4 训练参数设置

参数名称	参数值
训练样本数	7906
动作类别数	12
批量大小	8
输入尺寸	224
帧数	8
关节数	21
位姿数	32
随机丢弃损失	0.3
注意力头维度	4
TCN 卷积核大小	3
TCN 步长	[1, 2, 2]
TCN 膨胀率	[1, 2]
训练轮数	30
优化器	随机梯度下降
学习率	0.01
权重衰减	0.0005
动量	0.9
损失函数	交叉熵损失
标签平滑	0.1
温度参数	1.1

实验使用了 7,906 个训练样本，覆盖 12 个装配动作类别。网络输入设置

为 224×224 像素的 8 帧连续视频片段，每只手提取 21 个关节点特征。模型的关键参数包括：dropout 率为 0.3 以防止过拟合，注意力机制中每个头的维度为 4，时序卷积采用核大小为 3、步长[1,2,2]、扩张率[1,2]的多尺度结构。训练过程采用随机梯度下降（SGD）优化器，初始学习率设为 0.01，配合 0.0005 的权重衰减和 0.9 的动量参数。损失函数选用带标签平滑（smoothing=0.1）的交叉熵损失，温度系数设置为 1.1 以调节分类置信度。整个训练过程共进行 30 个 epoch，每个批次处理 8 个样本，在保证训练稳定性的同时兼顾计算效率。该参数配置经过多次验证实验优化确定，能够有效平衡模型性能和训练速度。

训练过程中，使用 tensorboard 分别记录了训练中学习率、损失、准确率的变化情况。学习率变化曲线如图 5-14 所示，损失变化曲线如图 5-15 所示，准确率变化曲线如图 5-16 所示。



图 5-8 学习率变化曲线

图 5-8 展示了学习率随训练轮次的变化情况。学习率在训练初期保持在 0.01 的水平，随后在第 10 轮和第 20 轮以每次下降为原来学习率的 0.1 的比率进行衰减。这种分段常数学习率策略在训练初期保持较高学习率以加速收敛过程，在训练后期通过降低学习率来实现对模型参数的精细调优。




图 5-9 损失变化曲线

图 5-9 展示了训练过程中损失的变化情况。可以观察到，模型在初始训练阶段表现出显著的损失函数下降趋势，表明模型在快速学习数据的特征。然而，在训练的中期，验证集损失函数出现了一定的波动，这可能是由于学习率较高

导致的模型参数更新不稳定。随着训练的进行，训练集和验证集的损失函数逐渐趋于稳定，并在训练后期保持在一个较低的水平，表明模型逐渐收敛。




图 5-10 精度变化曲线

图 5-10 展示了训练过程中模型准确率的变化情况。可以观察到，训练集和验证集的准确率在训练初期迅速上升，随后在训练的中期出现了一定的波动。这与损失函数的变化趋势相一致，进一步验证了模型在训练中期的不稳定状态。随着训练的进行，训练集和验证集的准确率逐渐趋于稳定，并在训练后期保持在一个较高的水平，最终在验证集上的精度达到了 95.31%，这表明模型具有良好的分类性能。




图 5-11 动作识别模型分类性能混淆矩阵

图 5-11 展示了本研究中动作识别模型在验证集上的混淆矩阵分析结果。

该混淆矩阵用于评估模型对不同动作类别的识别性能，其中行表示真实标签，列表示预测标签。通过分析混淆矩阵，可以直观地了解模型在各个类别上的分类准确性及其错误分类的情况。从混淆矩阵中可以看出，模型在大多数动作类别上的识别准确率较高，但是对于一些容易混淆的动作类别，如“安装前车身”和“安装后车身”，发生识别错误的概率相对其他动作类别较高。

图 5-12 展示了动作识别模型的可视化预测结果，其中包括每个动作的预测标签、对应的概率值以及实际标签。预测的概率有利于判断动作识别的难易程度，可视化预测结果不仅验证了模型在动作识别任务中的有效性，而且为进一步分析模型性能和优化提供了重要依据。



图 5-12 动作识别可视化预测结果




图 5-13 动作识别 CAM 热力图

本研究使用了类激活映射（CAM）技术对模型的关注区域进行可视化分

析。通过生成 CAM 热力图，可以直观地展示模型在进行动作分类决策时重点关注的区域。如图 5-13 所示，通过对 CAM 热力图的可视化分析发现，本模型在动作识别过程中主要关注装配区域内目标对象的状态变化特征，随着装配对象被拿起或者放下，关注的区域也会随着变动。这验证了模型的有效性，并且在一定程度上也增强了模型的可解释性。

5.4.2 动作预测实验与结果分析

本研究基于门控时序扩散网络构建动作预测模型，具体训练参数配置如表 5-5 所示。实验采用 batch size 为 16 的设置，输入特征维度为 2048，采样率为 6 帧。网络结构包含 5 个扩散阶段和 9 个隐藏层，扩散时间步长设置为 1000 步，其中前 5 个 epoch 采用 warm-up 策略逐步提升学习率。模型训练采用 Adam 优化器，初始学习率为 0.001，配合 0.3 的 dropout 率以防止过拟合。损失函数选用均方误差（MSE）来度量预测动作与实际动作的差异，整个训练过程持续 30 个 epoch。这种参数配置经过多次实验验证，能够在保证预测精度的同时维持训练稳定性。

表 5-5 训练参数设置

参数	设置
批量大小	16
特征维度	2048
降采样率	10
训练轮数	30
预热轮数	5
扩散步数	1000
阶段数	5
层数	9
优化器	Adam
学习率	0.001
随机丢弃率	0.3
损失函数	均方误差

图 5-14 展示了训练过程中的学习率变化曲线。实验采用基础学习率为 0.001 的设置，该参数经过多次预实验验证确定。训练过程中实施了学习率预热（warm-up）与阶段性衰减策略：在前 5 个 epoch 采用线性 warm-up 策略使学习率从 0 逐渐增至 0.001；后续在第 20 个 epoch 时衰减为原来的 0.1 倍，以便减少训练后期的震荡。

图 5-15 展示了训练集上的损失变化曲线。可以观察到，损失值在前 10 个

epoch 呈现快速下降趋势，10-20 个 epoch 期间损失值下降趋缓，表明模型进入稳定优化阶段；20 个 epoch 后损失值基本收敛，波动幅度小于 0.01，证明训练过程达到稳定状态。




图 5-14 学习率变化曲线




图 5-15 训练集损失变化曲线




图 5-16 训练集 MoF 变化曲线

如图 5-16 所示，三条曲线分别表示了已观测到的帧的标签预测的 MoF、未观测到的帧的标签预测的 MoF，以及所有帧的 MoF。观察可发现三者均呈现稳步上升趋势，并且逐渐收敛至稳定状态。这表明模型在训练过程中能够有效地学习到动作特征，并且随着训练的进行，模型的性能逐渐提高并趋于稳定。




图 5-17 测试集训练损失变化曲线

图 5-17 中的图 (a) 和图 (b) 分别展示了在不同观测比例 (0.2 和 0.3) 下测试集上的损失变化情况。可以观察到, 在两种观测比例下, 测试损失均呈现出随训练轮次增加而下降的趋势, 这表明模型在不断学习并逐渐适应测试数据。在初始阶段, 损失值下降较快, 随后逐渐趋于平缓, 显示出模型收敛的迹象, 这与训练集损失曲线下下降趋势一致。

图 5-18 展示了在不同观测比例 (0.2 和 0.3) 下, 模型在测试集上的 MoC 和 MoF 指标的变化趋势。具体而言, 图 5-18(a)和图 5-18 (c)分别显示了在观测比例为 0.2 和 0.3 时 MoC 指标的变化情况, 而图 5-18 (b)和图 5-18 (d)则展示了相同观测比例下 MoF 指标的变化。可以观察到, 在所有情况下, 随着训练轮次的增加, MoC 和 MoF 指标均呈现出明显的上升趋势, 表明模型对于动作上下文和特征的理解能力在不断提高。随着观测比例的提高, 预测的性能也随之提高; 随着预测比例的提高, 预测的难度增大, 预测的精度也逐渐下降, 这在四张图中表现一致。总体而言, 结果表明所提出的模型能够有效地从观测数据中学习并预测动作特征和上下文, 结果与理论是相符的。






图 5-18 测试集 MoC/MoF 变化曲线



(c)观测比例为 0.3 时的 MoC 曲线



(d)观测比例为 0.3 时的 MoF 曲线

图 5-18 (续图)

动作预测具体数值结果可以见表 5-6。

表 5-6 动作预测具体结果

观测比例	0.2				0.3			
预测比例	0.1	0.2	0.3	0.5	0.1	0.2	0.3	0.5
MoC	53.5	45.3	47.2	42.6	61.5	53.4	50.5	43.7
MoF	59.5	53.2	56.4	54.8	69.3	57.8	52.6	49.2

图 5-19 展示了使用门控时序扩散网络对推土机装配任务进行动作预测的结果可视化。该图包含了三个子图，分别对应观测比例为 0.3、0.4 和 0.5 的情况。每个子图中，最上方的条形图表示真实标签（Ground Truth），下方的条形图表示预测结果（Predicted），横轴为时间步（Time Steps）。图中不同颜色代表不同的动作类别，红色分割线用于区分观测部分和预测部分。随着观测比例的增加，模型的预测准确性显著提高，表明增加观测信息有助于提高动作预测的准确性，这一结果验证了门控时序扩散网络在动作预测任务中的有效性。



(a)观测比例为 0.3 时的预测结果



(b)观测比例为 0.4 时的预测结果

图 5-19 装配推土机的动作预测结果可视化



(c)观测比例为 0.5 时的预测结果

图 5-19（续图）

图 5-20 还展示了使用门控时序扩散网络对挖掘机装配任务进行动作预测的结果可视化，同样展示了观测比例为 0.3、0.4 和 0.5 时的动作预测情况。随着观测比例的增加，模型的预测准确性显著提高，这与推土机装配任务的表现一致。然而，挖掘机装配任务的动作预测表现明显不如推土机装配任务，这可能是由于挖掘机装配过程中的动作序列比推土机装配过程中的动作序列更加复杂多变，从而增加了模型学习的难度。这表明不同装配任务的动作序列复杂度可能对模型的预测性能产生显著影响。



(a)观测比例为 0.3 时的预测结果



(b)观测比例为 0.4 时的预测结果



(c)观测比例为 0.5 时的预测结果

图 5-20 装配挖掘机的动作预测结果可视化

在人机协作装配任务中，系统的实时响应能力是确保人机交互流畅性和安全性的关键因素。为此，本研究对动作预测模型的推理性能进行了系统性评估。测试方案设计如下：首先对计算设备进行充分的训练预热，以消除初始阶段可能存在的性能波动；随后，通过随机生成不同序列长度（ $T=100\sim10000$ ）的输入样本构建测试集，每个序列长度设置 100 个样本以保证统计显著性；最终采

用批量大小为 1 的推理模式，逐一样本输入模型并记录推理耗时，同时计算各序列长度下的平均推理时间、标准差以及对应的帧率（FPS）。详细的基准测试结果如表 5-7 所示。

表 5-7 动作识别模型推理速度测试结果

序列长度(T)	平均推理时间(s)	标准差	FPS
100	0.3239	0.0017	3.09
200	0.3068	0.0024	3.26
300	0.3131	0.0022	3.19
500	0.3137	0.0006	3.19
1000	0.3160	0.0011	3.16
2000	0.3176	0.0037	3.15
5000	0.4195	0.0020	2.38
10000	0.7631	0.0017	1.31

图 5-21 为动作预测网络模型推理时间与序列长度关系图，从中可以更直观地看出推理时间随着动作序列的变化情况。需要注意的是，本实验中的序列长度单位并非原始视频帧，而是经过降采样处理的时间步（时间步长由降采样率决定）。例如，当降采样率为 6 时，单个时间步对应实际视频中的 6 帧数据，3000 个时间步即表示 18000 帧，相当于 30FPS 视频中的 10 分钟时长。实验结果表明：在序列长度小于 5000（约合 83 分钟视频数据）的情况下，模型平均推理时间稳定在 0.42 秒以内；即使处理 10000 时间步（约合 166 分钟视频数据）的长序列，推理时间仍控制在 0.76 秒左右。这种毫秒级的响应速度完全满足人机协作装配场景下对实时动作预测的需求，为系统实现高效响应提供了可靠保障。




图 5-21 动作识别模型推理时间与序列长度关系图

5.5 本章小结

本章完成了实验平台的搭建与测试工作。在硬件方面，构建了包含协作机器人、装配工作区、零部件存放区及深度相机的综合实验平台；软件系统则集成了动作感知、识别与预测三大功能模块。通过采集多操作者、多装配对象、多装配序列的数据，建立了具有代表性和多样性的自建装配数据集。在动作识别实验中，详细记录了模型训练过程中的各项性能指标，并利用混淆矩阵和 CAM 热力图等方法对模型性能进行可视化分析。结果表明，动作识别模型在验证集上的精度达到了 95.31%，验证了所提出方法的有效性。动作预测实验同样记录了训练过程中的指标变化，并针对不同装配对象在不同观测比例下的预测结果进行了可视化分析。实验还测试了模型在不同步长下的推理速度，结果表明，在 10000 个时间步长的情况下，模型的推理速度能够控制在 1 秒以内，能够满足人机协作过程中的实时性需求。

结 论

本文针对制造业中协作机器人智能化及自然人机交互的需求，开展了人类装配动作识别与预测方法的研究。本文开发了一种纯视觉方案进行装配动作识别与预测，针对装配动作识别任务，采用了一种融合 RGB 视觉特征和手部关节运动特征的多模态数据驱动的装配动作识别方法，针对装配动作预测任务，采用了一种基于门控时序扩散网络的装配动作预测方法以实现长期动作预测。此外，本文还分别在公开数据集与自建数据集上对动作识别与动作预测方法进行实验验证。

本文的主要成果归纳如下：

1、构建了基于深度相机视觉感知系统，研究并实现了相机标定方法与手部位姿估计技术。通过搭建基于 MediaPipe Hands 框架的手部位姿估计方案，实现了手部关键点的实时检测，并结合深度信息和相机内参优化了手部关节点三维坐标，有效提高了位姿估计的鲁棒性。

2、设计并构建了一种多模态数据驱动的装配动作识别方法。该方法包括数据前处理、RGB 特征提取、关节点运动特征提取、多模态特征融合等模块，通过融合 RGB 图像特征和手部关节点特征，充分利用了多模态数据的互补性，有效实现了装配动作识别。基于公开数据集对模型的性能进行了评估，结果显示多模态的方案相较于单一模态的方案动作识别准确率提升了 4.24%，表明了多模态特征融合的有效性。

3、搭建了一种基于门控时序扩散网络的装配动作预测方法。该方法利用门控机制捕捉时序依赖关系，通过扩散过程预测未来的动作标签，实现了对装配动作序列的建模与预测。完成了整个动作预测网络框架的搭建，并基于公开数据集对模型的性能进行了评估，对比了与其他模型之间的性能差异，实验结果表明，所提方法在长时序动作预测任务的精度方面优于其他方法。

4、完成了实验硬件平台的搭建和软件系统的开发，设计了数据采集与标注方案，完成了自建装配数据集的构建工作。对动作识别任务展开实验，结果表明，动作识别模型在自建数据集上的精度达到了 95.31%，验证了所提出方法的有效性。对动作预测任务展开实验，对不同装配对象在不同观测比例下的预测结果进行了可视化分析，测试了模型在不同步长下的推理速度，结果表明，在 10000 个时间步长的情况下，动作预测模型的推理速度能够控制在 1 秒以内，能够满足人机协作过程中的实时性需求。

尽管本研究在装配场景下的动作识别与预测方面取得了一定成果，但由于研究条件和时间的限制，仍存在若干需要进一步完善和深入探索的问题：

1、数据集的规模与多样性有待提升。当前构建的自建数据集虽然在典型装配任务上具有代表性，但样本数量和场景覆盖仍显不足。未来研究需要采集更大规模、更具多样性的数据

2、长期预测精度需要进一步优化。实验表明，随着预测时间跨度的增加，当前模型的预测精度会逐步下降。后续研究可以从引入装配工艺知识图谱作为先验约束、设计层次化预测框架等方面进行改进。

3、预测结果与机器人控制的协同优化需要加强。目前的研究主要聚焦于动作识别与预测算法的精度提升，但对预测结果如何指导机器人进行自然、智能的交互还缺乏深入探讨。

参考文献

- [1] 梁绪,李文新,张航宁.人体行为识别方法研究综述[J].计算机应用研究,2022,39(03):651-660.DOI:10.19734/j.issn.1001-3695.2021.07.0350.
- [2] 裴利沈,刘少博,赵雪专.人体行为识别研究综述[J].计算机科学与探索,2022,16(02):305-322.
- [3] BOBICK A F, DAVIS J W. The recognition of human movement using temporal templates[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2001, 23(3): 257-267.
- [4] YILMAZ A, SHAH M. Actions sketch: a novel action representation[C].Proceedings of the 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, San Diego, Jun 20- 26, 2005. Washington: IEEE Computer Society, 2005: 984-989.
- [5] FUJIYOSHI H, LIPTON A J, KANADE T. Real- time human motion analysis by image skeletonization[J]. IEICE Transactions on Information and Systems,2004, E87-D(1): 113-120.
- [6] YANG X D, TIAN Y L. Effective 3D action recognition using eigen joints[J]. Journal of Visual Communication and Image Representation, 2014,25(1): 2-11.
- [7] LAPTEV I. On space-time interest points[J]. International Journal of Computer Vision, 2005: 107-123.
- [8] WANG H, SCHMID C. Action recognition with improved trajectories[C].Proceedings of the 2013 IEEE International Conference on Computer Vision,Sydney, Dec 1- 8, 2013. Washington: IEEE Computer Society, 2014: 3551-3558.
- [9] SIMONYAN K, ZISSERMAN A. Two- stream convolutional networks for action recognition in videos[C]. Proceedings of the Annual Conference on Neural Information Processing Systems, Montreal, Dec 8-13, 2014. Red Hook: Curran Associates, 2014: 568-576.
- [10] WANG L M, XIONG Y J, WANG Z, et al. Temporal segment networks: Towards good practices for deep action recognition[C]//European Conference on Computer Vision. Cham: Springer, 2016: 20-36.
- [11] FEICHTENHOFER C, PINZ A, WILDES R P. Spatiotemporal residual networks

- for video action recognition[C]. Proceedings of the Annual Conference on Neural Information Processing Systems, Barcelona, Dec 5- 10, 2016. Red Hook:Curran Associates, 2017: 3468-3476.
- [12] Qiu Z, Yao T, Ngo C W, et al. Learning spatio-temporal representation with local and global diffusion[C]//IEEE Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019: 12056-12065.
- [13] 王增强, 张文强, 张良. 引入高阶注意力机制的人体行为识别[J]. 信号处理, 2020,36(8): 1272-1279.
- [14] Ji S, Xu W, Yang M, et al. 3D convolutional neural networks for human action recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012, 35(1): 221-231.
- [15] Tran D, Bourdev L, Fergus R, et al. Learning spatiotemporal features with 3D convolutional networks [J] . IEEE Access, 2015, 7: 19087846.
- [16] Diba A, Fayyaz M, Sharma V, et al. Temporal 3D convnets: New architecture and transfer learning for video classification[J]. arXiv preprint arXiv:1711.08200, 2017.
- [17] Qiu Z, Yao T, Mei T. Learning spatio-temporal representation with pseudo-3D residual networks [C] . Proceedings of the IEEE International Conference on Computer Vision. Venice: IEEE, 2017: 5533-5541.
- [18] Kim J, Li Cen, Yun Inyong, et al. Weakly supervised temporal attention 3D network for human action recognition[J]. Pattern Recognition, 2021, 119: 108068
- [19] HE J Y, WU X, CHENG Z Q, et al. DB-LSTM: Densely-connected bi-directional LSTM for human action recognition[J]. Neurocomputing, 2021, 444: 319-331.
- [20] Girdhar R, Carreira J, Doersch C, Zisserman A. Video Action Transformer Network[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 244-253.
- [21] Zhou J, Lin K Y, Li H, Zheng W S. Graph-based high-order relation modeling for long-term action recognition[C]//Proceedings of the IEEE CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 8984-8993.
- [22] 孟祥璞, 李硕, 苑明哲, 等. 基于人体骨架的动作识别: 综述与展望[J]. 信息与控制, 2025, 54(01): 1-27. DOI:10.13976/j.cnki.xk.2024.3091.
- [23] LEE G, KIM D, KANG S, et al. Ensemble deep learning for skeleton-based action recognition using temporal sliding LSTM networks[C]//IEEE International

- Conference on Computer Vision. Venice: IEEE, 2017: 1012-1020.
- [24] Song S, Lan C, Xing J, Zeng W, Liu J. An end-to-end spatio-temporal attention model for human action recognition from skeleton data[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2017, 31.
- [25] Liu J, Wang G, Hu P, Duan L Y, Kot A C. Global context-aware attention lstm networks for 3d action recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 1647-1656.
- [26] Zhu W, Lan C, Xing J, Zeng W, Li Y, Shen L, Xie X. Cooccurrence feature learning for skeleton based action recognition using regularized deep lstm networks[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2016, 30.
- [27] Si C, Chen W, Wang W, Wang L, Tan T. An attention enhanced graph convolutional lstm network for skeleton-based action recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 1227-1236.
- [28] 王彩玲, 闫晶晶, 张智栋. 基于多模态数据的人体行为识别方法研究综述[J]. 计算机工程与应用, 2024, 60(09): 1-18.
- [29] Du Y, Fu Y, Wang L. Skeleton based action recognition with convolutional neural network[C]//3rd IAPR Asian Conference on Pattern Recognition (ACPR). IEEE, 2015: 579-583.
- [30] Ding Z, Wang P, Ogunbona P O, Li W. Investigation of different skeleton features for cnn-based 3d action recognition[C]//IEEE International Conference on Multimedia & Expo Workshops (ICMEW). IEEE, 2017: 617-622.
- [31] Liu J, Akhtar N, Mian A. Skepxels: Spatio-temporal image representation of human skeleton joints for action recognition[C]//CVPR Workshops. 2019.
- [32] Duan H, Zhao Y, Chen K, Lin D, Dai B. Revisiting skeleton-based action recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 2969-2978.
- [33] Yan S, Xiong Y, Lin D. Spatial temporal graph convolutional networks for skeleton-based action recognition[C]//Thirty-second AAAI Conference on Artificial Intelligence. 2018.
- [34] Li M, Chen S, Chen X, Zhang Y, Wang Y, Tian Q. Actional-structural graph convolutional networks for skeleton-based action recognition[C]//Proceedings of

- the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 3595-3603.
- [35] Zhang X, Xu C, Tao D. Context aware graph convolution for skeleton-based action recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 14333-14342.
- [36] Chen Y, Zhang Z, Yuan C, Li B, Deng Y, Hu W. Channel-wise topology refinement graph convolution for skeleton-based action recognition[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 13359-13368.
- [37] Wen X, Chen H. 3D long-term recurrent convolutional networks for human sub-assembly recognition in human-robot collaboration[J]. Assembly Automation, 2020, 40(4): 655-662.
- [38] Li S, Fan J, Zheng P, Wang L. Transfer Learning-enabled Action Recognition for Human-robot Collaborative Assembly[C]//Procedia CIRP. 2021, 104: 1795-1800.
- [39] Male J, Martinez-Hernandez U. Deep learning based robot cognitive architecture for collaborative assembly tasks[J]. Robotics and Computer-Integrated Manufacturing, 2023, 83: 102572.
- [40] 李芳. 基于骨骼特征的人体动作行为识别研究[D]. 华东交通大学, 2022. DOI:10.27147/d.cnki.ghdju.2022.000570.
- [41] 李琦. 基于 CNN-Transformer 的三维卷积人体动作识别研究[D]. 西安理工大学, 2023. DOI:10.27398/d.cnki.gxalu.2023.000505.
- [42] 张贺龙. 面向人机协作装配的人体动作意图识别研究[D]. 武汉理工大学, 2021. DOI:10.27381/d.cnki.gwlg.2021.001810.
- [43] 李佳英. 基于人体动作识别的人机协作装配感知和决策技术研究[D]. 上海大学, 2023. DOI:10.27300/d.cnki.gshau.2023.000797.
- [44] Damen D, Doughty H, Farinella G M, et al. The EPIC-KITCHENS Dataset: Collection, Challenges and Baselines[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 43(11): 4125-4141.
- [45] Grauman K, Westbury A, Torralba A, et al. Ego4D: Around the world in 3,000 hours of egocentric video[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New Orleans: IEEE, 2022: 18973-18990.
- [46] Sener F, Chatterjee D, Shelepov D, He K, Singhania D, Wang R, Yao A. Assembly101: A Large-Scale Multi-View Video Dataset for

- Understanding Procedural Activities[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, LA, USA: 2022: 21064-21074.
- [47] Kuehne H, Arslan A, Serre T. The language of actions: Recovering the syntax and semantics of goal-directed human activities[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition. Columbus: IEEE, 2014: 780-787.
- [48] Li Y, Liu M, Rehg JM. In the Eye of the Beholder: Gaze and Actions in First Person Video[J]. IEEE Trans Pattern Anal Mach Intell, 2023, 45(6):6731-6747. DOI: 10.1109/TPAMI.2021.3051319.
- [49] Girdhar R, Grauman K. Anticipative Video Transformer[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, QC, Canada: IEEE, 2021: 13485-13495.
- [50] Zhao Y, Krähenbühl P. Real-Time Online Video Detection with Temporal Smoothing Transformers[C]//Proceedings of the 16th European Conference on Computer Vision (ECCV). Cham: Springer, 2022: 428-445.
- [51] Zhong Z, Schneider D, Voit M, Stiefelhagen R, Beyerer J. Anticipative Feature Fusion Transformer for Multi-Modal Action Anticipation[C]//2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). Waikoloa, HI, USA: IEEE, 2023: 6057-6066.
- [52] Abu Farha Y, Richard A, Gall J. When will you do what?: Anticipating Temporal Occurrences of Activities[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Montreal, QC, Canada: IEEE, 2018: 5343-5352.
- [53] Abu Farha Y, Ke Q, Schiele B, Gall J. Long-Term Anticipation of Activities with Cycle Consistency[C]//Proceedings of the 42nd DAGM German Conference on Pattern Recognition (DAGM GCPR). Tübingen, Germany: Springer-Verlag, 2020: 159-173.
- [54] Gong D, Ke Q, Schiele B, et al. Future Transformer for Long-term Action Anticipation[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 3042-3051.
- [55] Ke Q, Fritz M, Schiele B. Time-conditioned action anticipation in one shot[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019: 9917-9926.
- [56] Nawhal M, Jyothi A A, Mori G. Rethinking learning approaches for long-term

- action anticipation[J]. arXiv preprint arXiv:2210.11566, 2022.
- [57] Sener F, Singhania D, Yao A. Temporal aggregate representations for long-range video understanding[J]. arXiv preprint arXiv:2006.00830, 2020.
- [58] Zhang J, Wang P, Gao R X. Hybrid machine learning for human action recognition and prediction in assembly[J]. Robotics and Computer-Integrated Manufacturing, 2021, 72:102184.
- [59] Zhang Z, Peng G, Wang W, et al. Prediction-based human-robot collaboration in assembly tasks using a learning from demonstration model[J]. Sensors, 2022, 22(11): 4279.
- [60] Zhang Y, Ding K, Hui J, et al. Human-object integrated assembly intention recognition for context-aware human-robot collaborative assembly[J]. Advanced Engineering Informatics, 2022, 54: 101792.
- [61] Li S, Zheng P, Fan J, et al. Toward proactive human - robot collaborative assembly: A multimodal transfer-learning-enabled action prediction approach[J]. IEEE Transactions on Industrial Electronics, 2021, 69(8): 8579-8588.
- [62] Zhang X, Tian S, Liang X, et al. Early Prediction of Human Intention for Human - Robot Collaboration Using Transformer Network[J]. Journal of Computing and Information Science in Engineering, 2024, 24(5): 051003.
- [63] Precup S A, Gellert A, Matei A, et al. Towards an assembly support system with dynamic bayesian network[J]. Applied Sciences, 2022, 12(3): 985.
- [64] 杜慧龙. 数据+知识驱动的人机协作装配意图识别与预测[D]. 西安理工大学, 2023. DOI:10.27398/d.cnki.gxalu.2023.000666.
- [65] 刘倡荣. 面向人机协作装配场景的操作者装配意图预测研究[D]. 西安理工大学, 2024. DOI:10.27398/d.cnki.gxalu.2024.000979.